

SMART PROPERTY VALUER: SISTEM RAMALAN  
HARGA HARTANAH DAN CADANGAN PINTAR DI  
SEKITAR MALAYSIA BERASASKAN  
PEMBELAJARAN MESIN

NUR BALQIS BINTI AHMAD RUSLI

UNIVERSITI KEBANGSAAN MALAYSIA

SMART PROPERTY VALUER: SISTEM RAMALAN HARGA HARTANAH DAN  
CADANGAN PINTAR DI SEKITAR MALAYSIA BERASASKAN  
PEMBELAJARAN MESIN

NUR BALQIS BINTI AHMAD RUSLI

LAPORAN USULAN PROJEK PROGRAM SARJANA MUDA  
SAINS KOMPUTER

FAKULTI TEKNOLOGI DAN SAINS MAKLUMAT  
UNIVERSITI KEBANGSAAN MALAYSIA  
BANGI

2025

**PENGAKUAN**

Saya akui karya ini adalah hasil kerja saya sendiri kecuali nukilan dan ringkasan yang tiap-tiap satunya telah saya jelaskan sumbernya.

30 Januari 2026

NUR BALQIS BINTI  
AHMAD RUSLI  
A202336

## **PENGHARGAAN**

Pertama sekali, saya ingin memanjatkan kesyukuran ke hadrat Allah SWT atas rahmat dan limpah kurnia-Nya yang telah memberikan saya kekuatan dan kesabaran dalam menyelesaikan projek akhir tahun saya bertajuk Smart Property Valuer: Sistem Ramalan Harga Hartanah Dan Cadangan Pintar Di Sekitar Malaysia Berasaskan Pembelajaran Mesin.

Ucapan terima kasih yang tidak terhingga saya tujukan khas kepada penyelia saya yang dihormati, Profesor Madya Dr. Mohammad Faizul Nasrudin, atas segala bimbingan, nasihat dan dorongan berterusan yang sangat berharga sepanjang projek ini dijalankan. Beliau telah memberi impak yang besar dalam memastikan kejayaan projek ini.

Saya juga ingin mengambil kesempatan ini untuk merakamkan setinggi-tinggi penghargaan kepada Fakulti Teknologi dan Sains Maklumat (FTSM) atas segala kemudahan yang disediakan. Terima kasih juga diucapkan kepada semua pensyarah yang telah mendidik saya sepanjang saya bergelar mahasiswa di Universiti Kebangsaan Malaysia (UKM) serta kakitangan fakulti yang telah memberikan sokongan teknikal dan moral. Tanpa sokongan daripada mereka, adalah mustahil untuk saya mencapai hasil yang memuaskan di tahap ini.

Akhir sekali, ucapan jutaan terima kasih saya tujukan kepada semua pihak yang terlibat secara langsung mahupun tidak langsung dalam menjayakan projek ini, terutamanya keluarga, rakan-rakan, dan individu-individu yang sentiasa memberikan sokongan moral dan dorongan sepanjang tempoh projek ini dijalankan.

## ABSTRAK

Pasaran hartanah di Malaysia, khususnya di Selangor, telah mengalami perkembangan pesat dalam beberapa tahun kebelakangan ini, namun pembeli hartanah sering berhadapan dengan kesukaran dalam memilih hartanah yang sesuai dengan bajet, lokasi dan keperluan mereka akibat harga yang berubah-ubah serta pengaruh pelbagai faktor seperti ciri fizikal rumah, kemudahan awam dan aksesibiliti kawasan. Bagi menangani masalah ini, kajian ini bertujuan untuk membangunkan sistem Smart Property Valuer, iaitu satu sistem ramalan harga dan cadangan hartanah pintar berasaskan pembelajaran mesin. Sistem ini menggunakan bahasa pengaturcaraan Python untuk proses pra-pemprosesan data hartanah dan model yang terbaik sama ada Random Forest Regression atau XGBoost bagi meramalkan harga hartanah berdasarkan ciri-ciri seperti saiz rumah, jenis hartanah dan lokasi. Selain itu, analisis geospasial turut diintegrasikan dengan menggunakan koordinat geografi (latitud dan longitud) bagi mengenal pasti kemudahan berhampiran seperti stesen LRT/MRT dan kemudahan awam lain yang mempengaruhi nilai hartanah. Sistem ini dibangunkan sebagai aplikasi web berasaskan rangka kerja Flask dan pangkalan data MySQL bagi membolehkan pengguna melihat maklumat hartanah, mendapatkan ramalan harga serta menerima cadangan hartanah yang bersesuaian. Hasil kajian ini dijangka dapat menyediakan sokongan keputusan yang lebih berinformasi dan membantu pembeli, penyewa serta pemilik hartanah membuat keputusan yang lebih tepat dalam pasaran hartanah Malaysia.

## **SMART PROPERTY VALUER: A MACHINE LEARNING BASED REAL ESTATE PRICE PREDICTION AND INTELLIGENT RECOMMENDATION SYSTEM IN MALAYSIA**

### **ABSTRACT**

The property market in Malaysia, particularly in Selangor, has experienced rapid growth in recent years. However, property buyers often face difficulties in selecting properties that match their budget, location, and personal requirements due to fluctuating prices and the influence of various factors such as physical housing characteristics, public amenities, and area accessibility. To address this issue, this study aims to develop a Smart Property Valuer system, a machine learning based property price prediction and recommendation system. The system utilises the Python programming language for property data pre-processing and applies the most suitable predictive model, either Random Forest Regression or XGBoost, to estimate property prices based on features such as property size, property type, and location. In addition, geospatial analysis is integrated using geographical coordinates (latitude and longitude) to identify nearby facilities such as LRT/MRT stations and other public amenities that influence property values. The system is developed as a web-based application using the Flask framework and a MySQL database, allowing users to view property information, obtain price predictions, and receive property recommendations that match their preferences. The findings of this study are expected to provide more informed decision support and assist buyers, renters, and property owners in making more accurate decisions within the Malaysian property market.

## KANDUNGAN

|                                                           | <b>Halaman</b> |
|-----------------------------------------------------------|----------------|
| <b>PENGAKUAN</b>                                          | ii             |
| <b>PENGHARGAAN</b>                                        | iii            |
| <b>ABSTRAK</b>                                            | iv             |
| <b>ABSTRACT</b>                                           | v              |
| <b>KANDUNGAN</b>                                          | vi             |
| <b>SENARAI JADUAL</b>                                     | ix             |
| <b>SENARAI ILUSTRASI</b>                                  | x              |
| <b>SENARAI SINGKATAN</b>                                  | xi             |
| <b>BAB I      PENDAHULUAN</b>                             |                |
| 1.1          Pengenalan                                   | 1              |
| 1.2          Penyataan Masalah                            | 2              |
| 1.3          Cadangan Penyelesaian Masalah                | 3              |
| 1.4          Objektif Kajian                              | 5              |
| 1.5          Skop Kajian                                  | 5              |
| 1.6          Kekangan                                     | 6              |
| 1.7          Metodologi                                   | 7              |
| 1.8          Jadual Pelaksanaan                           | 11             |
| 1.9          Kesimpulan                                   | 12             |
| <b>BAB II      SOROTAN KESUSTERAAN</b>                    |                |
| 2.1          Pengenalan                                   | 13             |
| 2.2          Penyelidikan Terkini Dan Teknologi Berkaitan | 14             |
| 2.3          Metodologi Dalam Kajian Lepas                | 16             |
| 2.4          Bandingan Dan Kritik Kajian Lepas            | 18             |
| 2.5          Jurang Dalam Penyelidikan                    | 19             |
| 2.6          Penyelesaian Inovatif Dalam Kajian Lepas     | 21             |
| 2.7          Rumusan                                      | 22             |

|                |                                                 |    |
|----------------|-------------------------------------------------|----|
| <b>BAB III</b> | <b>ANALISIS DAN SPESIFIKASI KEPERLUAN</b>       |    |
| 3.1            | Pengenalan                                      | 24 |
| 3.2            | Data                                            |    |
| 3.2.1          | Keperluan Data                                  | 25 |
| 3.2.2          | Analisis Struktur Data                          | 26 |
| 3.3            | Pra-Pemprosesan Data                            |    |
| 3.3.1          | Pembersihan Data Teks                           | 26 |
| 3.3.2          | Pembersihan Metadata                            | 29 |
| 3.3.3          | Transformasi Data                               | 35 |
| 3.3.4          | Pemilihan Atribut                               | 37 |
| 3.3.5          | Geokodan Dan Kejuteraan Ciri                    | 37 |
| 3.3.6          | Set Data Akhir                                  | 38 |
| 3.4            | Analisis Dekriptif                              | 43 |
| 3.5            | Rumusan                                         | 44 |
| <b>BAB IV</b>  | <b>SPESIFIKASI REKA BENTUK DAN PENILAIAN</b>    |    |
| 4.1            | Pengenalan                                      | 45 |
| 4.2            | Pemilihan Algoritma Dan Justifikasi             | 46 |
| 4.2.1          | Pemilihan Algoritma                             | 48 |
| 4.2.2          | Model Seni Bina                                 | 52 |
| 4.3            | Strategi Eksperimen                             | 56 |
| 4.3.1          | Pembahagian Data                                | 56 |
| 4.3.2          | Penalaan Hiperparameter (Hyperparameter Tuning) | 57 |
| 4.4            | Reka Bentuk Penilaian                           |    |
| 4.4.1          | Metrik Prestasi                                 | 58 |
| 4.5            | Spesifikasi Keperluan Sistem                    |    |
| 4.5.1          | Keperluan Fungsian                              | 60 |
| 4.5.2          | Spesifikasi Perkakasan Dan Perisian             | 62 |



|       |                                    |    |
|-------|------------------------------------|----|
| 4.6   | Reka Bentuk Sistem Dan Antara Muka |    |
| 4.6.1 | Seni Bina Sistem                   | 64 |
| 4.6.2 | Carta Alir Proses                  | 65 |
| 4.6.3 | Reka Bentuk Antara Muka Pengguna   | 66 |
| 4.7   | Rumusan                            | 68 |
|       | <b>RUJUKAN</b>                     | 69 |

## SENARAI JADUAL

| No. Jadual  |                                                                             | Halaman |
|-------------|-----------------------------------------------------------------------------|---------|
| Jadual 1.1  | Jadual Pelaksanaan                                                          | 11      |
| Jadual 2.1  | Keputusan menunjukkan bahawa model (Ho et al. 2021)                         | 16      |
| Jadual 2.2  | Keputusan menunjukkan bahawa model (Pastukh, Khomyshyn 2024)                | 17      |
| Jadual 2.3  | Keputusan menunjukkan bahawa model (Mathotaarachchi et al. 2024)            | 18      |
| Jadual 2.4  | Perbandingan antara platform hartanah sedia ada                             | 19      |
| Jadual 3.1  | Senarai Set Data Beserta Atribut                                            | 26      |
| Jadual 3.2  | Senarai atribut yang mengandungi data tiada nilai dan tindakan yang diambil | 29      |
| Jadual 3.3  | Senarai Atribut Yang Mempunyai Hanya Satu Nilai                             | 31      |
| Jadual 3.4  | Nilai Data Tidak Seragam bagi Atribut <i>Furnishing</i>                     | 32      |
| Jadual 3.5  | Nilai Data Tidak Seragam bagi Atribut <i>Occupancy</i>                      | 33      |
| Jadual 3.6  | Nilai Data Tidak Seragam bagi Atribut <i>Unit_Type</i>                      | 34      |
| Jadual 3.7  | Nilai Data Tidak Seragam bagi Atribut <i>Tenure</i>                         | 34      |
| Jadual 3.8  | Nilai Data Tidak Seragam bagi Atribut <i>Propert_Type</i>                   | 35      |
| Jadual 3.9  | Senarai Atribut Norminal Dengan Perwakilan Dan Jenis Data                   | 36      |
| Jadual 3.10 | Senarai atribut geospatial dan atribut baharu yang terhasil                 | 38      |
| Jadual 3.11 | Senarai Set Data Akhir                                                      | 38      |
| Jadual 3.12 | Analisis data Deskriptif                                                    | 43      |
| Jadual 4.1  | Keperluan fungsian sistem                                                   | 60      |
| Jadual 4.2  | Keperluan Perisian Pembangunan ( <i>SOFTWARE</i> )                          | 62      |
| Jadual 4.3  | Keperluan Perisian Pengguna ( <i>SOFTWARE</i> )                             | 63      |
| Jadual 4.4  | Keperluan Perkakasan Pembangunan dan Pengguna ( <i>HARDWARE</i> )           | 64      |

## SENARAI ILUSTRASI

| No. Rajah  |                                                                                           | Halaman |
|------------|-------------------------------------------------------------------------------------------|---------|
| Rajah 1.1  | Fasa-fasa pelaksanaan kajian                                                              | 10      |
| Rajah 3.1  | Rangka kerja analisis dan pra pemrosesan data di dalam fasa penyediaan data.              | 25      |
| Rajah 3.2  | Aktiviti pemprosesan data teks                                                            | 28      |
| Rajah 3.3  | Nilai Data Tidak Relevan Bagi Atribut <i>Bedroom</i>                                      | 31      |
| Rajah 3.4  | Graf Histogram Perbandingan Taburan Data <i>Price</i> sebelum dan Selepas Pembersihan     | 39      |
| Rajah 3.5  | Graf Histogram Perbandingan Taburan Data <i>Land_Size</i> sebelum dan Selepas Pembersihan | 40      |
| Rajah 3.6  | Box Plot Perbandingan Taburan Data <i>Price</i> sebelum dan Selepas Pembersihan           | 41      |
| Rajah 4.1  | Konsep <i>Random Forest Regression</i>                                                    | 48      |
| Rajah 4.2  | Struktur pemodelan <i>XGBoost</i> yang berperingkat                                       | 50      |
| Rajah 4.3  | Seni Bina Model Bagi Sistem Smart Property Valuer                                         | 54      |
| Rajah 4.4  | Kes Guna Sistem Smart Property Valuer                                                     | 60      |
| Rajah 4.5  | Seni Bina Sistem Smart PropertyValuer                                                     | 63      |
| Rajah 4.6  | Carta Alir Proses Sistem Smart PropertyValuer                                             | 64      |
| Rajah 4.7  | Reka Bentuk Antara Muka Halaman Utama Smart Property Valuer                               | 65      |
| Rajah 4.8  | Reka Bentuk Antara Muka Halaman Ramalan Smart Property Valuer                             | 65      |
| Rajah 4.9  | Reka Bentuk Antara Muka Halaman Ramalan Harga Smart Property Valuer                       | 65      |
| Rajah 4.10 | Reka Bentuk Antara Muka Halaman Carian Tapisan Hartanah Smart Property Valuer             | 66      |
| Rajah 4.11 | Reka Bentuk Antara Muka Halaman Paparan Carian Hartanah Smart Property Valuer             | 66      |
| Rajah 4.12 | Reka Bentuk Antara Muka Halaman Butiran Hartanah Smart Property Valuer                    | 66      |

**SENARAI SINGKATAN**

|         |                                                         |
|---------|---------------------------------------------------------|
| API     | Application Programming Interface                       |
| AI      | Artificial Intelligence (Kecerdasan Buatan)             |
| BNM     | Bank Negara Malaysia                                    |
| DP      | DurianProperty                                          |
| GBM     | Gradient Boosting Machine                               |
| IQR     | Interquartile Range                                     |
| JK      | Jawatankuasa                                            |
| LRT     | Light Rail Transit                                      |
| MAE     | Mean Absolute Error                                     |
| ML      | Machine Learning                                        |
| MRT     | Mass Rapid Transit                                      |
| NLP     | Natural Language Processing (Pemprosesan Bahasa Semula) |
| $R^2$   | Coefficient of Determination                            |
| RMSE    | Root Mean Squared Error                                 |
| UI      | User Interface                                          |
| UKM     | Universiti Kebangsaan Malaysia                          |
| XAI     | Explainable Artificial Intelligence                     |
| XGBoost | Extreme Gradient Boosting                               |

## **BAB I**

### **PENDAHULUAN**

#### **1.1 PENGENALAN**

Pasaran hartanah di Malaysia telah mengalami pertumbuhan yang pesat dalam beberapa tahun kebelakangan ini, dipacu oleh faktor seperti peningkatan pendapatan, kemajuan infrastruktur, dan permintaan yang semakin meningkat daripada golongan muda serta pelabur luar. Dengan jumlah penduduk yang semakin berkembang dan keperluan ruang kediaman yang semakin meningkat, pasaran hartanah Malaysia menawarkan pelbagai pilihan hartanah untuk dibeli, baik di kawasan bandar mahupun luar bandar. Walau bagaimanapun, pembeli hartanah, terutamanya golongan muda dan pembeli pertama kali, sering kali berhadapan dengan kesukaran dalam memilih hartanah yang sesuai dengan keperluan dan bajet mereka.

Menurut Laporan Kestabilan Kewangan oleh Bank Negara Malaysia (BNM, 2020), harga hartanah di Malaysia terus menunjukkan peningkatan yang ketara, dengan harga rumah di kawasan bandar utama seperti Kuala Lumpur, Pulau Pinang, dan Johor Bahru mengalami kenaikan melebihi 4% setahun. Kenaikan harga hartanah yang pesat ini menjadikan pembelian rumah lebih mencabar, terutamanya bagi pembeli rumah pertama kali yang menghadapi kesukaran dalam mencari hartanah yang berpatutan. Selain itu, faktor seperti lokasi, kemudahan awam di sekeliling kawasan hartanah, serta aksesibiliti pengangkutan menjadi isu utama yang mempengaruhi keputusan pembelian.

Kebanyakan pembeli, terutama mereka yang baru pertama kali membeli hartanah, sering tidak mempunyai pengetahuan yang mencukupi mengenai pasaran hartanah tempatan. Mereka juga kurang memahami kesan faktor-faktor seperti jarak ke pusat bandar, kemudahan pengangkutan awam seperti stesen LRT/MRT, serta

kehadiran sekolah atau pusat membeli-belah yang berdekatan, yang kesemuanya boleh mempengaruhi nilai hartanah. Kekurangan maklumat yang sistematik dan tepat mengenai hartanah dan kemudahan berhampiran menyebabkan pembeli berisiko membuat keputusan yang kurang tepat.

Menyedari cabaran ini, penggunaan pembelajaran mesin (machine learning) menawarkan penyelesaian yang inovatif dalam meramalkan harga hartanah berdasarkan pelbagai faktor seperti saiz, jenis rumah, lokasi, dan kemudahan sekeliling. Kajian ini bertujuan untuk membangunkan satu sistem Smart Property Valuer yang menggunakan pembelajaran mesin untuk meramalkan harga hartanah di seluruh Malaysia, serta memberi cadangan hartanah yang relevan berdasarkan ciri-ciri yang dimasukkan oleh pengguna. Sistem ini juga akan mengintegrasikan analisis geospasial untuk mengenal pasti kemudahan berhampiran seperti stesen pengangkutan awam, sekolah, dan pusat membeli-belah, menggunakan koordinat geografi (latitude dan longitude) untuk membantu pembeli membuat keputusan yang lebih baik dan tepat.

## **1.2 PERNYATAAN MASALAH**

Dalam pasaran hartanah di Malaysia, pembeli sering menghadapi masalah kekurangan maklumat yang sistematik mengenai harga hartanah yang tepat berdasarkan faktor-faktor seperti saiz rumah, bilangan bilik, jenis rumah, serta lokasi. Walaupun terdapat banyak platform pengiklanan hartanah yang menyediakan maklumat hartanah, kebanyakan mereka tidak menyediakan sistem ramalan harga yang tepat berdasarkan faktor-faktor ini secara dinamik dan tidak menawarkan cadangan yang relevan berdasarkan keperluan pembeli. Ini menyebabkan pembeli sukar untuk membuat keputusan yang tepat dan berinformasi ketika membeli hartanah.

Selain itu, data yang sangat banyak ini sering tersebar dan tidak teratur, menjadikannya sukar untuk digunakan secara langsung untuk analisis dan ramalan. Kebanyakan platform hanya menyediakan maklumat harga dan ciri hartanah tanpa menyusun data tersebut dengan cara yang membolehkan analisis lebih mendalam. Oleh itu, walaupun maklumat tersebut banyak, ia tidak dapat dimanfaatkan sepenuhnya untuk menyediakan ramalan harga yang lebih tepat dan cadangan hartanah yang relevan.

Satu lagi isu utama ialah set data yang ada tidak menyediakan koordinat geografi seperti longitud dan latitud. Ini penting untuk analisis geospasial yang akan membantu dalam meramalkan kemudahan berhampiran seperti stesen pengangkutan awam, sekolah, pusat membeli-belah, dan kemudahan awam lain yang mempengaruhi nilai hartanah. Oleh kerana set data tidak lengkap, data longitude dan latitude perlu diekstrak dan ditambahkan secara manual berdasarkan lokasi bandar di seluruh Malaysia. Ini menambah kesukaran dan masa yang diperlukan untuk memproses dan menyediakan data yang tepat untuk ramalan harga hartanah dan analisis geospasial.

Oleh itu, terdapat keperluan untuk membangunkan sistem yang boleh meramalkan harga hartanah secara tepat dan memberi cadangan hartanah yang relevan berdasarkan keperluan dan pilihan pembeli, serta menyediakan analisis geospasial untuk kemudahan yang berdekatan. Sistem ini juga perlu menangani isu pengumpulan dan penstrukturan data yang lebih teratur, serta menyelesaikan masalah pengekstrakan koordinat geografi untuk analisis yang lebih mendalam.

### **1.3 CADANGAN PENYELESAIAN MASALAH**

Berdasarkan masalah yang telah dikenal pasti, beberapa penyelesaian boleh diterapkan untuk menangani isu-isu utama yang dihadapi dalam projek ini. Salah satu masalah utama yang perlu diatasi adalah kekurangan platform yang boleh meramalkan harga hartanah dengan tepat dan memberikan cadangan hartanah yang relevan. Di pasaran hartanah Malaysia, tidak terdapat platform yang menawarkan ramalan harga berdasarkan pelbagai ciri yang lengkap dan disesuaikan dengan keperluan pembeli, seperti lokasi, saiz rumah, bilangan bilik, kemudahan berhampiran, dan faktor geospasial. Oleh itu, membangunkan sistem yang dapat meramalkan harga rumah dan menyediakan cadangan hartanah yang relevan berdasarkan data yang terkini dan tepat adalah langkah pertama untuk menangani masalah ini.

Selain itu, masalah seterusnya yang perlu diatasi ialah data yang tidak teratur dan tersebar, yang menyukarkan proses analisis dan ramalan. Dalam pasaran hartanah, maklumat yang ada sering kali tidak terstruktur dengan baik, menjadikan ia sukar untuk digunakan dalam model peramalan harga yang tepat. Oleh itu, pra pemrosesan data yang melibatkan pembersihan, normalisasi, dan penyusunan data dengan cara yang

lebih teratur adalah langkah penting. Data seperti harga rumah, saiz, bilangan bilik tidur, dan maklumat berkaitan kemudahan awam perlu diuruskan dengan baik supaya ia dapat digunakan dengan lebih efektif dalam model pembelajaran mesin.

Satu lagi isu yang timbul ialah set data yang ada tidak menyediakan koordinat geografi seperti longitud dan latitud, yang amat penting untuk analisis geospasial. Koordinat geografi diperlukan untuk menentukan jarak antara hartanah dengan kemudahan berhampiran seperti stesen pengangkutan awam, sekolah, dan pusat membeli-belah, yang mempengaruhi nilai hartanah. Sekiranya koordinat ini tidak tersedia dalam set data, ia boleh dijana menggunakan API peta seperti Google Maps API atau OpenStreetMap API. Melalui geocoding, kita dapat menukar alamat atau nama kawasan hartanah kepada koordinat geografi (longitude dan latitude) dan menambahkannya ke dalam set data untuk analisis lanjut.

Seterusnya, untuk menyediakan ramalan harga yang lebih tepat, sistem ini akan menggunakan model pembelajaran mesin seperti Random Forest Regression untuk menganalisis faktor-faktor seperti saiz rumah, bilangan bilik tidur, dan jenis hartanah, serta faktor lokasi. Pembelajaran mesin akan digunakan untuk meramalkan harga berdasarkan ciri-ciri tersebut. Dengan model yang tepat, pengguna dapat memperoleh ramalan harga yang lebih akurat dan relevan. Di samping itu, sistem ini akan mengintegrasikan analisis geospasial untuk memberikan maklumat tentang kemudahan berhampiran, seperti stesen LRT/MRT mahupun lokasi sekolah berdasarkan koordinat geografi hartanah. Ini akan memberi pembeli gambaran lebih lengkap mengenai aksesibiliti dan nilai hartanah yang mereka minati.

Akhir sekali, untuk memastikan sistem memberi cadangan hartanah yang disesuaikan dengan keperluan pengguna, algoritma keserupaan kosinus (cosine similarity) akan digunakan. Algoritma ini akan membandingkan hartanah yang diinginkan oleh pengguna dengan hartanah lain yang ada dalam pangkalan data berdasarkan ciri-ciri yang serupa, seperti harga, saiz, jenis rumah, dan lokasi. Dengan cara ini, sistem akan dapat memberi cadangan hartanah yang paling relevan dengan keperluan dan pilihan pengguna.



## 1.4 OBJEKTIF KAJIAN

Tujuan utama projek ini adalah untuk :

1. Membangunkan sistem Smart Property Valuer yang dapat meramalkan harga hartanah berdasarkan ciri-ciri seperti lokasi, saiz rumah, jenis rumah, bilangan bilik tidur, bilangan bilik mandi, dan kemudahan berhampiran, serta menyediakan cadangan hartanah yang relevan berdasarkan keperluan pengguna.
2. Meramalkan harga hartanah dengan menggunakan model pembelajaran mesin (machine learning) seperti Random Forest Regression dan XGBoost, serta memberikan cadangan hartanah yang relevan berdasarkan analisis keserupaan kosinus. Keberkesanan ramalan harga akan diukur melalui metrik Mean Absolute Error (MAE) dan Root Mean Squared Error (RMSE). Keberkesanan cadangan hartanah pula akan dinilai berdasarkan kepuasan pengguna yang menggunakannya.
3. Membangunkan model pembelajaran mesin dan pra pemrosesan data, serta Google Maps API atau OpenStreetMap API untuk mengekstrak koordinat geografi bagi analisis geospasial. Dengan memanfaatkan rangka kerja seperti Flask dan MySQL, sistem akan dibangunkan sebagai aplikasi web yang berfungsi dengan baik untuk pengguna.

## 1.5 SKOP KAJIAN

Projek Smart Property Valuer akan membangunkan sebuah sistem untuk meramalkan harga hartanah dan memberi cadangan hartanah yang relevan berdasarkan pelbagai faktor. Sistem ini akan menggunakan pembelajaran mesin, khususnya model Random Forest Regression dan XGBoost, untuk meramalkan harga hartanah berdasarkan atribut seperti saiz rumah, lokasi, bilangan bilik tidur, bilangan bilik mandi, dan jenis hartanah. Selain itu, sistem ini akan mengintegrasikan analisis geospasial menggunakan API peta seperti Google Maps API atau OpenStreetMap API untuk mendapatkan koordinat geografi (longitude dan latitude) bagi kemudahan berhampiran seperti stesen

LRT/MRT, sekolah, dan pusat membeli-belah, yang akan membantu dalam penilaian aksesibilitas dan nilai hartanah.

Sistem ini akan dibangunkan sebagai aplikasi web menggunakan Flask dan MySQL untuk pengurusan pangkalan data hartanah. Pengguna akan dapat melihat maklumat hartanah, menghubungi tuan rumah, dan mendapatkan cadangan hartanah yang relevan. Dalam aspek pengurusan data, sistem ini akan melakukan prapemprosesan dan pembersihan data untuk memastikan hanya data yang teratur dan boleh digunakan dalam ramalan harga. Keberkesanan sistem akan dinilai dengan menggunakan metrik seperti *Mean Absolute Error (MAE)* dan *Root Mean Squared Error (RMSE)*, serta melalui penilaian kepuasan pengguna berdasarkan cadangan hartanah yang diberikan.

Namun, sistem ini tidak akan merangkumi pembangunan aplikasi mudah alih, dan akan hanya fokus pada platform web. Ia juga tidak akan menyertakan fungsi kemas kini harga pasaran hartanah secara automatik atau memberi maklumat terperinci mengenai tinjauan pasaran hartanah. Pengurusan pembayaran atau transaksi hartanah juga tidak akan disertakan dalam skop projek ini, kerana sistem ini hanya bertujuan untuk meramalkan harga dan memberi cadangan hartanah.

Dengan demikian, skop projek ini memastikan tumpuan pada pembangunan sistem ramalan harga hartanah yang tepat dan memberikan cadangan hartanah berdasarkan keperluan pengguna, tanpa melibatkan aspek transaksi atau kajian pasaran hartanah yang lebih mendalam.

## **1.6 KEKANGAN**

Terdapat beberapa kekangan yang berpotensi menghalang dan membatasi pelaksanaan projek Smart Property Valuer ini. Salah satu kekangan utama adalah akses kepada data pasaran hartanah yang terkini dan tepat. Walaupun terdapat banyak platform pengiklanan hartanah, data yang tersedia sering kali tidak lengkap atau tidak dikemas kini secara berkala. Hal ini menyebabkan sukar untuk mendapatkan maklumat yang boleh digunakan untuk membuat ramalan harga yang tepat. Di samping itu, data yang tidak teratur dan tersebar di pelbagai sumber menyukarkan proses analisis dan

pembelajaran mesin. Proses prapemrosesan untuk membersihkan dan menyusun data menjadi teratur memerlukan banyak masa dan usaha.

Selain itu, projek ini memerlukan kemahiran tinggi dalam pembelajaran mesin dan analisis geospasial, namun akses kepada pakar dalam bidang ini mungkin menjadi kekangan. Pembangunan model pembelajaran mesin dan integrasi analisis geospasial memerlukan kepakaran yang mendalam, dan sekiranya tidak ada sokongan atau kepakaran yang mencukupi, ini boleh melambatkan proses pembangunan sistem.

Kekangan lain yang mungkin timbul adalah berkaitan dengan kerahsiaan dan privasi data. Penggunaan data hartanah yang melibatkan maklumat peribadi pemilik atau penyewa perlu mematuhi undang-undang perlindungan data yang ketat. Tanpa langkah keselamatan yang sesuai, data mungkin terdedah kepada risiko pelanggaran privasi, yang akan memberi kesan kepada integriti projek.

Secara keseluruhan, walaupun terdapat beberapa kekangan yang mungkin menghalang pelaksanaan projek ini, dengan perancangan yang teliti dan sumber yang mencukupi, masalah-masalah ini dapat diatasi untuk memastikan projek dapat disiapkan dengan jayanya.

## **1.7 METODOLOGI PENYELIDIKAN**

Dalam projek Smart Property Valuer, model proses pembangunan yang paling sesuai adalah *Incremental Development Process* (Pembangunan Secara Berperingkat). Model ini dipilih kerana ia membenarkan pembangunan dan pengujian dilakukan secara berperingkat, membolehkan setiap fasa dibangunkan dan diuji secara teratur, sambil memastikan projek dapat diselesaikan dalam tempoh yang ditetapkan dengan tahap keberkesanan yang tinggi. Berikut adalah penjelasan mengenai setiap fasa dalam *Incremental Development Process* yang digunakan dalam projek ini.

Fasa pertama iaitu Kajian Literatur. Pada peringkat awal, kajian literatur dilakukan untuk mengkaji teori dan pendekatan yang berkaitan dengan ramalan harga hartanah, algoritma pembelajaran mesin, serta analisis geospasial. Ini termasuk kajian tentang model pembelajaran mesin yang relevan seperti Random Forest Regression dan

XGBoost, serta kaedah pengumpulan dan penggunaan data geospasial untuk analisis kemudahan berhampiran. Kajian literatur adalah langkah pertama dalam memastikan bahawa pendekatan yang digunakan adalah berlandaskan teori yang kukuh dan amalan terbaik dalam industri.

Fasa kedua merupakan penyediaan data. Pada fasa ini, data hartanah dikumpulkan dari pelbagai sumber yang relevan. Data ini kemudian dibersihkan dan diproses untuk memastikan kualiti dan konsistensi sebelum digunakan dalam pembangunan model ramalan. Proses ini termasuk pengendalian nilai hilang, normalisasi data, dan penukaran data tidak terstruktur kepada format yang sesuai. Penyediaan data adalah langkah penting untuk memastikan bahawa data yang digunakan untuk melatih model adalah tepat, teratur, dan bersih. Tanpa penyediaan data yang baik, model pembelajaran mesin yang dibangunkan tidak akan dapat memberikan ramalan yang tepat.


Seterusnya, Fasa ketiga, Geocoding (Longitude & Latitude). Setelah data hartanah disediakan, koordinat geografi (longitude dan latitude) bagi setiap hartanah perlu diekstrak untuk membolehkan analisis geospasial. Sekiranya koordinat tidak disediakan dalam set data asal, API peta seperti Google Maps API digunakan untuk mengekstrak koordinat berdasarkan lokasi. Geocoding adalah langkah penting untuk analisis geospasial, yang membolehkan sistem mengira jarak antara hartanah dan kemudahan berhampiran seperti stesen LRT/MRT, sekolah, pusat membeli-belah, dan kemudahan lain. Ini memberikan konteks tambahan yang membantu dalam ramalan harga hartanah.

Fasa keempat ialah Latihan Model (Random Forest, XGBoost) ataupun pembangunan algoritma pembelajaran. Pada fasa ini, model pembelajaran mesin seperti Random Forest Regression dan XGBoost digunakan untuk melatih model ramalan harga hartanah berdasarkan data yang telah diprapemproses. Model ini akan menganggarkan harga rumah berdasarkan atribut seperti saiz rumah, jenis hartanah, dan lokasi. Selepas itu, model diuji untuk memastikan ketepatan ramalan menggunakan metrik seperti MAE (Mean Absolute Error) dan RMSE (Root Mean Squared Error). Model ini dipilih kerana ia telah terbukti berkesan dalam ramalan harga hartanah dan

dapat menangani data yang tidak linear dan pelbagai pembolehubah. Dengan menggunakan Random Forest dan XGBoost, sistem dapat memberikan ramalan harga yang lebih tepat dan relevan.

Diteruskan dengan fasa kelima iaitu Pembangunan Antara Muka Pengguna (UI). Setelah model ramalan dibangunkan dan diuji, antaramuka pengguna (UI) dibangunkan menggunakan Flask. Aplikasi web ini membolehkan pengguna memasukkan maklumat hartanah mereka dan mendapatkan ramalan harga. Pengguna juga boleh mendapatkan cadangan hartanah berdasarkan keperluan dan pilihan mereka, serta melihat maklumat hartanah yang relevan. Pembangunan UI adalah penting untuk memastikan pengalaman pengguna yang mudah dan interaktif. Dengan antaramuka yang mudah digunakan, pengguna dapat berinteraksi dengan sistem untuk mendapatkan maklumat yang diperlukan.

Fasa keenam iaitu Pengujian dan Penilaian Pada peringkat akhir, sistem diuji secara menyeluruh untuk memastikan semua fungsi berfungsi dengan baik. Pengujian model dilakukan untuk memastikan ketepatan ramalan harga hartanah, dan penilaian kepuasan pengguna diambil untuk memastikan cadangan hartanah yang diberikan adalah relevan dan bermanfaat. Maklum balas daripada pengguna akan digunakan untuk meningkatkan dan memperbaiki sistem. Pengujian adalah langkah penting untuk memastikan bahawa sistem berfungsi dengan lancar dan memenuhi keperluan pengguna. Penilaian membantu dalam mengidentifikasi kelemahan yang perlu diperbaiki sebelum implementasi akhir.



Rajah 1.1 Fasa-fasa pelaksanaan kajian

Model Incremental Development dipilih kerana ia membenarkan pembangunan dan pengujian dilakukan secara berperingkat, memberikan fleksibiliti untuk melakukan pembetulan dan penambahbaikan sepanjang proses pembangunan. Pendekatan ini juga membolehkan fokus pada bahagian-bahagian penting dalam projek dan memastikan sistem diuji secara menyeluruh di setiap fasa. Dengan menggunakan pendekatan ini, setiap modul atau komponen sistem diuji dan disahkan sebelum bergerak ke fasa seterusnya, mengurangkan risiko kesilapan yang lebih besar pada peringkat akhir. Ini amat sesuai untuk projek yang melibatkan pembelajaran mesin dan analisis geospasial yang memerlukan pengujian dan penyesuaian yang teliti.

| AKTIVITI /MINGGU                                | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 |
|-------------------------------------------------|---|---|---|---|---|---|---|---|---|----|----|----|----|----|
| Perjumpaan 1                                    |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Kemaskini tajuk dan sinopsis                    |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Perancangan Projek (D1)                 |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan1: Perancangan Projek (D1)               |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Sorotan Susastera (D2)                  |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Merancang dan menyediakan spesifikasi keperluan |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 2: Sorotan Susastera (D2)               |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Spesifikasi Keperluan (D3)              |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 3: Spesifikasi Keperluan (D3)           |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Spesifikasi Reka Bentuk (D4)            |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Spesifikasi Reka Bentuk (D4)            |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 4: Menulis Spesifikasi Reka Bentuk (D4) |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Laporan Usulan (D5)                     |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 5: Laporan Usulan (D5)                  |   |   |   |   |   |   |   |   |   |    |    |    |    |    |

| AKTIVITI /MINGGU                                | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 |
|-------------------------------------------------|---|---|---|---|---|---|---|---|---|----|----|----|----|----|
| Perjumpaan 1                                    |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Kemaskini tajuk dan sinopsis                    |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Perancangan Projek (D1)                 |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan1: Perancangan Projek (D1)               |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Sorotan Susastera (D2)                  |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Merancang dan menyediakan spesifikasi keperluan |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 2: Sorotan Susastera (D2)               |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Spesifikasi Keperluan (D3)              |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 3: Spesifikasi Keperluan (D3)           |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Spesifikasi Reka Bentuk (D4)            |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Spesifikasi Reka Bentuk (D4)            |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 4: Menulis Spesifikasi Reka Bentuk (D4) |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Menulis Laporan Usulan (D5)                     |   |   |   |   |   |   |   |   |   |    |    |    |    |    |
| Serahan 5: Laporan Usulan (D5)                  |   |   |   |   |   |   |   |   |   |    |    |    |    |    |

## 1.9 KESIMPULAN

Projek Smart Property Valuer bertujuan untuk membangunkan sistem yang dapat meramalkan harga hartanah dengan tepat dan memberikan cadangan hartanah yang relevan berdasarkan faktor seperti lokasi, saiz rumah, jenis hartanah, kemudahan berhampiran dan lain-lain. Masalah utama yang dihadapi adalah kekurangan platform yang dapat meramalkan harga secara tepat, serta ketidakteraturan data yang menyukarkan analisis dan kekurangan koordinat geografi untuk analisis geospasial. Oleh itu, projek ini akan menggunakan pembelajaran mesin dan analisis geospasial untuk memberikan ramalan harga yang lebih tepat dan cadangan hartanah yang sesuai dengan pilihan pengguna. Sistem ini akan dibangunkan sebagai aplikasi web dengan menggunakan Flask dan MySQL, dan akan berfokus pada rumah kediaman. Terdapat beberapa kekangan, termasuk akses kepada data terkini, kerumitan dalam penyusunan data, dan kekurangan koordinat geografi dalam set data. Untuk itu, Incremental Development dipilih sebagai model proses pembangunan kerana ia membolehkan sistem dibangunkan secara berperingkat, dengan setiap fasa diuji dan diperbaiki secara teliti. Projek ini akan menyediakan sokongan keputusan yang lebih baik dalam pasaran hartanah Malaysia, membantu pembeli membuat keputusan yang lebih bijak berdasarkan ramalan harga dan kemudahan berhampiran.



## **BAB II**

### **SOROTAN KESUSTERAAN**

#### **2.1 PENGENALAN**

Dalam era pembangunan bandar dan pertumbuhan ekonomi yang pesat, harga hartanah menjadi faktor utama dalam perancangan kewangan, pelaburan hartanah, dan pembangunan komuniti. Oleh itu, projek ini bertujuan untuk membangunkan Sistem Ramalan Harga Hartanah dan Cadangan Pintar di Seluruh Malaysia Berasaskan Pembelajaran Mesin, yang akan menggunakan data hartanah sebenar untuk meramalkan harga rumah dan mencadangkan pilihan hartanah terbaik berdasarkan ciri-ciri yang ditentukan oleh pengguna. Sistem ini akan mengambil kira pelbagai atribut rumah, termasuk lokasi, saiz, jenis rumah, bilangan bilik tidur, bilangan bilik mandi, serta kemudahan sekitar, dan mengaplikasikan ciri geospasial seperti jarak ke pusat bandar untuk meningkatkan ketepatan ramalan.

Topik ini sangat penting kerana sistem-sistem sedia ada seperti PropertyGuru, iProperty, EdgeProp, dan platform-platform lain hanya memaparkan harga pasaran semasa atau data sejarah hartanah tanpa memberikan ramalan harga berdasarkan ciri-ciri khusus rumah secara pintar. Kebanyakan platform ini menawarkan maklumat hartanah berdasarkan penyenaraian yang disediakan oleh pemilik hartanah dan agen, tetapi tidak memberikan ramalan harga atau cadangan yang disesuaikan untuk pembeli. Dengan menggunakan pembelajaran mesin, sistem yang dibangunkan dalam projek ini mampu memberikan ramalan harga yang lebih tepat dan menyediakan cadangan hartanah yang relevan mengikut kriteria pengguna, membolehkan mereka membuat keputusan pembelian yang lebih bijak.

Projek ini dipilih kerana terdapat permintaan yang tinggi untuk alat ramalan harga hartanah pintar di Malaysia, terutamanya untuk pembeli rumah pertama, pelabur hartanah, dan perancang bandar yang mencari sistem yang dapat memberi lebih daripada sekadar data harga pasaran. Selain itu, projek ini memberi peluang untuk mengaplikasikan kemahiran dalam pembelajaran mesin dan analitik data, serta analisis geospasial dalam sistem cadangan pintar. Berbanding dengan platform seperti Propsocial, StarProperty, Bumbung.co, dan Durian Property, yang hanya menyediakan penyenaraian hartanah berdasarkan harga pasaran dan lokasi, sistem ini menawarkan pendekatan yang lebih dinamik dan disesuaikan untuk meramalkan harga dan memberi cadangan hartanah terbaik berdasarkan keperluan individu. Dengan ini, projek ini bukan sahaja relevan dari segi akademik, tetapi juga memberi manfaat praktikal kepada pengguna dan industri hartanah di Malaysia.

## **2.2 PENYELIDIKAN TERKINI DAN TEKNOLOGI BERKAITAN**

Dalam beberapa tahun kebelakangan ini, kajian mengenai ramalan harga hartanah menggunakan Pembelajaran Mesin (Machine Learning, ML) telah menunjukkan potensi besar dalam membantu pembeli, pelabur, dan perancang bandar membuat keputusan yang lebih tepat. Kajian-kajian terkini di Malaysia dan luar negara menggabungkan pelbagai model pembelajaran mesin seperti Random Forest, dan XGBoost untuk meramalkan harga rumah berdasarkan pelbagai ciri hartanah, termasuk lokasi, saiz, umur rumah, dan kemudahan sekitar. Kajian oleh Pastukh dan Khomyshyn (2025) menunjukkan bahawa teknik ensemble machine learning seperti Random Forest, Gradient Boosting Regressor dan Extra Trees Regressor mampu memberikan prestasi ramalan harga hartanah yang tinggi serta lebih konsisten berbanding kaedah tunggal kerana keupayaan mereka mengekalkan kestabilan model dan mengurangkan bias berdasarkan jumlah data sejarah. Hasil kajian menunjukkan bahawa teknik XGBoost dapat menangkap hubungan yang kompleks antara faktor-faktor ini dengan lebih tepat, serta memberikan ramalan harga yang lebih baik berbanding kaedah tradisional seperti regresi hedonik dan penilaian manual.

Sebagai contoh, kajian oleh Aditya Gofi (2022) dalam artikel Predicting House Prices with XGBoost: A Machine Learning Journey menunjukkan bahawa penggunaan model XGBoost mampu meningkatkan ketepatan ramalan harga rumah dengan ketara

berbanding kaedah regresi tradisional. Kajian ini mendapati bahawa XGBoost berupaya memodelkan hubungan tidak linear antara ciri-ciri hartanah seperti saiz rumah, lokasi dan bilangan bilik dengan lebih berkesan, sekali gus mengurangkan nilai ralat ramalan seperti Mean Absolute Error (MAE) dan Root Mean Squared Error (RMSE).

Berbanding dengan platform teknologi sedia ada di Malaysia seperti iProperty, PropertyGuru, EdgeProp, dan Propsocial, yang menawarkan platform untuk mencari hartanah tetapi hanya memaparkan harga berdasarkan maklumat yang dimasukkan oleh pengguna atau data pasaran terkini, tiada sistem yang secara dinamik meramalkan harga hartanah berdasarkan ciri-ciri rumah tertentu menggunakan pembelajaran mesin. Platform-platform ini lebih banyak bergantung kepada penyenaraian hartanah yang disediakan oleh pemilik atau agen hartanah dan penilaian pasaran yang kasar. Oleh itu, pengguna masih perlu bergantung kepada penilaian manual atau perbandingan harga secara kasar, tanpa sistem ramalan yang automatik dan disesuaikan.

Brickz.my, sebagai contoh lain, menyediakan data transaksi sebenar (sub-sale) yang termasuk harga unit, saiz, jenis hartanah, dan lokasi, yang membolehkan analisis harga sejarah dan penilaian hartanah. Walau bagaimanapun, Brickz.my hanya menawarkan data pasaran bersejarah dan tidak menyediakan ramalan harga secara automatik. Data yang ada juga hanya mencakupi transaksi yang telah berlaku, yang menyebabkan ia tidak dapat digunakan untuk projek yang belum dijual atau unit baru.

Memandangkan kekurangan yang ada dalam teknologi sedia ada, sistem yang dicadangkan dalam projek ini bertujuan untuk mengisi jurang tersebut. Dengan menggunakan pembelajaran mesin (terutama model Random Forest), sistem ini akan meramalkan harga rumah secara automatik berdasarkan data transaksi sebenar dan penyenaraian hartanah, serta mengintegrasikan analisis geospasial untuk mengenal pasti kemudahan berhampiran seperti stesen LRT/MRT, pusat membeli-belah, dan sekolah yang mempengaruhi nilai hartanah. Sistem ini juga menyediakan cadangan rumah terbaik berdasarkan harga ramalan dan kriteria pengguna, serta membolehkan pengguna melakukan tinjauan dan penapisan hartanah secara interaktif. Pendekatan ini seiring dengan trend terkini dalam teknologi hartanah (PropTech) yang semakin menggabungkan analitik berasaskan data, Kecerdasan Buatan (AI), dan pembelajaran

mesin (ML) untuk membantu pengguna membuat keputusan pelaburan hartanah yang lebih bijak.

Teknologi ini telah memberi impak besar kepada industri hartanah, dengan membolehkan pengguna mendapatkan ramalan harga yang lebih tepat dan lebih cepat, serta menyediakan cadangan hartanah yang lebih relevan mengikut keperluan individu, berbanding hanya bergantung kepada maklumat penyenaraian dan harga pasaran yang sedia ada. Projek ini bukan sahaja relevan dalam konteks akademik, tetapi juga berpotensi memberi manfaat praktikal kepada pengguna, pelabur hartanah, dan industri hartanah di Malaysia.

## 2.2 METODOLOGI DALAM KAJIAN LEPAS

Ramalan harga hartanah merupakan satu masalah regresi yang kompleks kerana harga dipengaruhi oleh pelbagai faktor seperti saiz, lokasi, umur bangunan dan ciri persekitaran. Model regresi linear tradisional sering gagal menangkap hubungan tidak linear antara pembolehubah-pembolehubah ini. Oleh itu, kajian terkini semakin menumpukan kepada penggunaan model pembelajaran mesin berasaskan ensemble seperti Random Forest dan XGBoost bagi meningkatkan ketepatan ramalan.

Kajian ini menggunakan data transaksi hartanah di Hong Kong melibatkan lebih 39,000 rekod dan membandingkan tiga algoritma pembelajaran mesin, iaitu Support Vector Machine (SVM), Random Forest (RF) dan Gradient Boosting Machine (GBM). Penilaian prestasi dilakukan menggunakan  $R^2$ , MSE, RMSE dan MAPE pada set ujian. Keputusan menunjukkan bahawa model berasaskan pokok keputusan ensemble (RF dan GBM) memberikan prestasi yang jauh lebih baik berbanding SVM dari segi ketepatan ramalan di Jadual 2.1

Jadual 2.1 Keputusan menunjukkan bahawa model (Ho et al. 2021)

| Bil. | Model                    | $R^2$ | RMSE  | MAPE   |
|------|--------------------------|-------|-------|--------|
| 1    | <i>SVM</i>               | 0.827 | 0.119 | 0.545% |
| 2    | <i>Random Forest</i>     | 0.903 | 0.089 | 0.323% |
| 3    | <i>Gradient Boosting</i> | 0.904 | 0.089 | 0.323% |

Kajian ini membuktikan bahawa Random Forest dan Boosting lebih sesuai untuk ramalan harga hartanah berbanding SVM. (Ho et al. 2021)

Seterusnya, Kajian ini memfokuskan sepenuhnya kepada ensemble learning, menggunakan lapan model ensemble untuk meramal harga hartanah berdasarkan data jualan di Ternopil, Ukraine. Antara model yang diuji ialah AdaBoost, Bagging, Extra Trees, Gradient Boosting, Hist Gradient Boosting, Random Forest, Stacking dan Voting Regressor. Keputusan penilaian prestasi dibuat menggunakan  $R^2$ , RMSE dan MAE di jadual 2.2 .

Jadual 2.2 Keputusan menunjukkan bahawa model (Pastukh, Khomyshyn 2024)

| <b>Bil.</b> | <b>Model</b>                       | <b><math>R^2</math></b> | <b>RMSE</b> | <b>MAE</b> |
|-------------|------------------------------------|-------------------------|-------------|------------|
| 1           | <i>Gradient Boosting Regressor</i> | 0.724                   | 11,980      | 8,113      |
| 2           | <i>Extra Trees Regressor</i>       | 0.696                   | 12,563      | 8,691      |
| 3           | <i>Random Forest Regressor</i>     | 0.688                   | 12,745      | 8,731      |
| 4           | <i>AdaBoost Regressor</i>          | 0.641                   | 13,664      | 10,739     |
| 5           | <i>Stacking Regressor</i>          | 0.571                   | 14,932      | 10,612     |

Hasil kajian menunjukkan bahawa Gradient Boosting mencapai prestasi terbaik, manakala Random Forest memberikan prestasi yang stabil dan hampir setara. (Pastukh & Khomyshyn 2023)

Di samping itu, Kajian lain menjalankan analisis menyeluruh terhadap pelbagai model regresi termasuk regresi linear, model ensemble (Random Forest, XGBoost, LightGBM, CatBoost) dan model hibrid. Selain itu, kajian ini turut menguji kebolehan generalization model menggunakan set data luaran (Ames Housing). Dalam set ujian utama tanpa regularization, Random Forest menunjukkan prestasi yang seimbang dan mantap berbanding model ensemble lain. Keputusan penilaian prestasi dibuat menggunakan  $R^2$ , RMSE dan MAE di jadual 2.3 .

Jadual 2.3 Keputusan menunjukkan bahawa model (Mathotaarachchi et al. (2024))

| Bil. | Model                | RMSE( $\times 10^6$ ) | MAE ( $\times 10^3$ ) | R <sup>2</sup> |
|------|----------------------|-----------------------|-----------------------|----------------|
| 1    | <i>Random Forest</i> | 0.782                 | 38.6                  | 0.93           |
| 3    | <i>XGBoost</i>       | 1.382                 | 114.9                 | 0.77           |
| 4    | <i>LightGBM</i>      | 1.972                 | 83.7                  | 0.53           |
| 5    | <i>CatBoost</i>      | 2.054                 | 77.5                  | 0.49           |

Kajian ini menyimpulkan bahawa walaupun XGBoost mampu memberikan ketepatan tinggi dalam sesetengah keadaan, Random Forest adalah lebih stabil dan mudah digeneralisasikan kepada data baharu(Mathotaarachchi et al. 2024)

Secara keseluruhan, ketiga-tiga kajian yang dianalisis menunjukkan dapatan yang konsisten bahawa model pembelajaran mesin berasaskan ensemble pokok keputusan mengatasi model regresi tradisional dalam tugas ramalan harga hartanah. Random Forest didapati memberikan prestasi yang stabil dan kukuh merentas dataset yang berbeza, menjadikannya sesuai digunakan sebagai model asas (baseline) kerana ketahanannya terhadap variasi data dan risiko overfitting yang lebih rendah. Sementara itu, model boosting seperti Gradient Boosting dan XGBoost menunjukkan potensi untuk mencapai ketepatan ramalan yang lebih tinggi dengan keupayaan menangkap hubungan tidak linear dan interaksi kompleks antara ciri-ciri hartanah, walaupun memerlukan penalaan parameter yang lebih teliti serta berisiko overfitting jika tidak dikawal dengan baik. Oleh itu, berdasarkan bukti empirikal daripada kajian terdahulu, pemilihan Random Forest dan XGBoost dalam pembangunan sistem ramalan harga hartanah adalah wajar dan relevan, bukan sahaja dari sudut akademik tetapi juga dari segi praktikal, kerana ia membolehkan perbandingan yang bermakna antara kestabilan model dan ketepatan ramalan.

## 2.4 BANDINGAN DAN KRITIK KAJIAN LEPAS

Berikut adalah perbandingan ciri ciri antara platform sedia ada dan sistem yang dicadangkan (Smart Property Valuer) berdasarkan ciri-ciri yang ada dalam projek Smart Property Valuer:

Jadual 2.4 Perbandingan antara platform hartanah sedia ada

| Ciri-ciri                                                                    | Portal Sedia Ada                  |           | Smart Property Valuer (Sistem yang ingin dibangunkan) |
|------------------------------------------------------------------------------|-----------------------------------|-----------|-------------------------------------------------------|
|                                                                              | iProperty, PropertyGuru, EdgeProp | Brickz.my |                                                       |
| Mencari hartanah ikut lokasi, bilik, harga, jenis rumah                      | Tersedia                          | Tersedia  | Tersedia                                              |
| Paparan senarai sebenar seperti gambar, info unit, harga                     | Tersedia                          | Tersedia  | Tersedia tetapi tiada gambar                          |
| Paparan data transaksi/harga pasaran ' <i>subscale</i> '                     | Tiada                             | Tersedia  | Tiada                                                 |
| Ramalan harga berdasarkan ciri dipilih                                       | Tiada                             | Tiada     | Tersedia                                              |
| ML model yang digunakan                                                      | Tiada                             | Tiada     | Tersedia - Random Forest                              |
| Cadangan rumah terbaik berdasarkan hasil ramalan & pemilihan pengguna        | Tiada                             | Tiada     | Tersedia                                              |
| Penapisan dan peninjauan data secara interaktif                              | Tersedia                          | Tersedia  | Tersedia                                              |
| Keputusan data berbasis ML/data transaksi & statistik, Ramalan Harga Terkini | Tiada                             | Tiada     | Tersedia                                              |

## 2.5 JURANG DALAM PENYELIDIKAN

Kajian terdahulu mengenai ramalan harga hartanah menggunakan Pembelajaran Mesin (Machine Learning, ML) telah menunjukkan potensi besar, tetapi masih terdapat beberapa jurang yang belum diteroka dengan mendalam. Sebagai contoh, banyak kajian yang menggunakan model seperti Random Forest, Gradient Boosting, dan lain-lain berjaya meramalkan harga hartanah berdasarkan faktor-faktor seperti saiz, jenis rumah,

dan lokasi. Namun, kajian ini sering terjadi pada penggunaan set data yang tidak komprehensif, di mana data yang digunakan tidak mengintegrasikan faktor-faktor lain yang mungkin memberi impak besar kepada harga hartanah, seperti kemudahan berhampiran, akses pengangkutan awam, dan perubahan harga dari masa ke masa. Platform-platform hartanah sedia ada, seperti iProperty dan PropertyGuru, walaupun memberikan data pasaran yang luas, hanya memaparkan harga hartanah berdasarkan penyenaraian yang disediakan oleh pemilik atau agen tanpa meramalkan harga secara automatik berdasarkan ciri-ciri rumah tertentu.

Selain itu, analisis geospasial yang mempertimbangkan lokasi dan jarak kemudahan seperti stesen LRT/MRT, pusat membeli-belah, dan sekolah jarang digunakan dalam kajian ramalan harga hartanah. Oleh kerana itu, kekurangan analisis geospasial ini menjadikan banyak ramalan harga hartanah tidak begitu tepat, kerana faktor-faktor kemudahan berhampiran yang mempengaruhi nilai hartanah tidak diambil kira. Kajian yang ada juga cenderung terhad kepada data sejarah sahaja tanpa mengambil kira dinamika pasaran hartanah semasa.

Projek yang dicadangkan, Smart Property Valuer, bertujuan untuk mengisi jurang ini dengan menggunakan pembelajaran mesin (ML), khususnya model Random Forest dan XGBoost, untuk meramalkan harga hartanah secara lebih tepat berdasarkan ciri-ciri rumah yang lebih menyeluruh, seperti lokasi, saiz rumah, bilangan bilik, umur rumah, dan kemudahan berhampiran. Dengan menggunakan analisis geospasial, sistem ini akan mengira jarak ke pusat bandar, stesen LRT/MRT, dan kemudahan lain yang mempengaruhi harga hartanah. Oleh itu, sistem ini akan dapat memberi ramalan harga hartanah yang lebih dinamik dan tepat, mengambil kira lebih banyak faktor yang mempengaruhi pasaran hartanah. Ini akan mengatasi kekurangan sistem sedia ada yang hanya memberikan harga pasaran semasa atau penyenaraian hartanah tanpa membuat ramalan berdasarkan faktor-faktor tertentu.

Dengan mengintegrasikan analisis geospasial dan pembelajaran mesin, projek ini bertujuan untuk menyediakan penyelesaian pintar yang lebih relevan dan tepat kepada pengguna yang ingin membuat keputusan pelaburan hartanah yang lebih bijak.



Ini akan memberi manfaat kepada pembeli rumah pertama, pelabur hartanah, dan perancang bandar yang mencari alat ramalan harga yang lebih dinamik dan disesuaikan.

## **2.6 PENYELESAIAN INOVATIF DALAM KAJIAN LEPAS**

Kajian-kajian terdahulu dalam bidang ramalan harga hartanah menggunakan Pembelajaran Mesin (Machine Learning, ML) telah menunjukkan peningkatan ketara dari segi ketepatan ramalan, terutamanya melalui penggunaan model berasaskan ensemble seperti Random Forest dan Gradient Boosting. Model-model ini didapati lebih berkesan berbanding pendekatan regresi tradisional dalam menangkap hubungan tidak linear antara ciri-ciri hartanah dan harga pasaran. Walau bagaimanapun, masih terdapat beberapa jurang penyelidikan yang belum diteroka secara menyeluruh dalam kajian sedia ada.

Salah satu jurang utama ialah keterbatasan set data dan ciri yang digunakan dalam kebanyakan kajian terdahulu. Banyak kajian hanya memfokuskan kepada ciri asas hartanah seperti keluasan, jenis kediaman, bilangan bilik dan tahun pembinaan, tanpa mengintegrasikan ciri persekitaran dan lokasi secara terperinci. Faktor-faktor seperti kemudahan berhampiran, akses kepada pengangkutan awam, serta jarak ke pusat aktiviti ekonomi jarang dianalisis secara kuantitatif walaupun ia memainkan peranan penting dalam penentuan nilai hartanah. Selain itu, sebahagian kajian hanya menggunakan data sejarah tanpa mengambil kira perubahan dinamik pasaran semasa yang boleh menjejaskan ketepatan ramalan dalam konteks sebenar.

Di samping itu, penggunaan analisis geospasial dalam ramalan harga hartanah masih terhad. Walaupun lokasi sering dikenal pasti sebagai faktor utama dalam penentuan harga, banyak model ramalan hanya menggunakan maklumat lokasi secara umum tanpa pengiraan jarak sebenar kepada kemudahan penting seperti stesen LRT/MRT, sekolah, pusat membeli-belah dan kawasan komersial. Kekurangan integrasi analisis geospasial ini menyebabkan ramalan harga yang dihasilkan kurang mencerminkan keadaan sebenar pasaran, khususnya di kawasan bandar yang mempunyai kepadatan dan variasi kemudahan yang tinggi.

Dari sudut aplikasi praktikal pula, platform hartanah sedia ada seperti iProperty dan PropertyGuru berfungsi terutamanya sebagai platform penyenaraian yang memaparkan maklumat hartanah serta harga yang dicadangkan oleh pemilik atau ejen. Sistem ini tidak dibangunkan sebagai sistem ramalan harga berasaskan pembelajaran mesin, sebaliknya bertindak sebagai medium penyampaian maklumat pasaran semasa. Oleh itu, harga yang dipaparkan tidak dihasilkan melalui proses pemodelan atau analisis automatik berdasarkan ciri-ciri hartanah tertentu, seperti lokasi, kemudahan berhampiran atau interaksi antara ciri-ciri tersebut. Keadaan ini menjadikan fungsi platform sedia ada berbeza daripada sistem yang dicadangkan, yang memberi tumpuan kepada ramalan harga hartanah secara analitik dan berasaskan data menggunakan teknik pembelajaran mesin.

Sehubungan itu, projek yang dicadangkan iaitu Smart Property Valuer bertujuan untuk mengisi jurang ini dengan mengaplikasikan pembelajaran mesin berasaskan ensemble, khususnya model Random Forest mahupun XGBoost, bagi menghasilkan ramalan harga hartanah yang lebih tepat dan boleh dipercayai. Sistem ini akan menggunakan set ciri yang lebih menyeluruh merangkumi ciri struktur hartanah, ciri lokasi dan ciri persekitaran, termasuk analisis geospasial untuk mengira jarak kepada kemudahan utama yang mempengaruhi nilai hartanah. Pendekatan ini membolehkan sistem menghasilkan ramalan harga yang bukan sahaja bersifat dinamik, malah disokong oleh kaedah analitik yang jelas dan telus.

Secara keseluruhannya, pengintegrasian pembelajaran mesin berasaskan ensemble dengan analisis geospasial dalam projek ini diharapkan dapat menyediakan satu penyelesaian pintar yang lebih tepat dan berasas berbanding platform sedia ada. Penyelesaian ini berpotensi menyokong pembuatan keputusan yang lebih baik dalam sektor hartanah, khususnya bagi pembeli rumah, pelabur hartanah dan pihak berkepentingan dalam perancangan bandar.

## 2.7 RUMUSAN

Kajian-kajian terdahulu menunjukkan bahawa pembelajaran mesin dan analisis geospasial dapat meningkatkan ketepatan ramalan harga hartanah dengan meramalkan harga berdasarkan ciri-ciri yang lebih terperinci dan kemudahan berhampiran. Walau

bagaimanapun, banyak kajian yang masih terhad kepada data sejarah atau harga pasaran semasa, tanpa memperhitungkan faktor-faktor yang lebih luas. Platform sedia ada seperti iProperty dan PropertyGuru tidak menggunakan teknologi pembelajaran mesin untuk meramalkan harga berdasarkan ciri-ciri rumah tertentu, dan lebih bergantung kepada maklumat yang dimasukkan oleh pengguna.

Kajian ini memberi rasional untuk menjalankan projek Smart Property Valuer kerana ia mengatasi kekurangan dalam ramalan harga hartanah yang terdapat dalam sistem sedia ada. Dengan menggunakan pembelajaran mesin dan analisis geospasial, projek ini akan menawarkan penyelesaian yang lebih tepat dan disesuaikan kepada pengguna yang ingin membuat keputusan pelaburan hartanah yang lebih bijak. Dapatan ini menyokong perkembangan teknologi dalam PropTech dan memberi manfaat praktikal kepada pengguna dan industri hartanah di Malaysia.

## **BAB III**

### **ANALISIS DAN SPESIFIKASI KEPERLUAN**

#### **3.1 PENGENALAN**

Bab ini membincangkan analisis data serta spesifikasi keperluan yang terlibat dalam pembangunan sistem Smart Property Valuer. Fokus utama bab ini adalah terhadap proses penyediaan data hartanah yang digunakan sebagai asas kepada pembangunan model pembelajaran mesin dan sistem cadangan hartanah. Analisis yang sistematik terhadap data adalah penting bagi memastikan kualiti data yang tinggi, seterusnya meningkatkan ketepatan ramalan harga dan keberkesanan cadangan hartanah yang dihasilkan oleh sistem.

Bab ini merangkumi penerangan mengenai sumber data, struktur set data, serta proses pra-pemprosesan data yang melibatkan pembersihan, penyeragaman, transformasi, dan pemilihan atribut. Selain itu, proses geokodan dan kejuruteraan ciri turut dibincangkan bagi memperkayakan set data dengan maklumat geospasial seperti koordinat latitud dan longitud, yang memainkan peranan penting dalam menilai pengaruh lokasi terhadap harga hartanah.

Analisis deskriptif turut dijalankan bagi memahami taburan dan corak data hartanah selepas proses pra-pemprosesan, termasuk pengendalian nilai luar biasa dan nilai hilang. Keseluruhan proses yang dibincangkan dalam bab ini bertujuan untuk menyediakan set data akhir yang bersih, konsisten dan sesuai digunakan dalam fasa latihan serta penilaian model pembelajaran mesin yang akan diterangkan dalam bab seterusnya.


## 3.2 DATA

### 3.2.1 Keperluan Data

Data mentah penyenggaraan hartanah dikumpulkan secara rawak dan diekstrak daripada laman web agensi hartanah tempatan, iaitu DurianProperty (DP), yang menyediakan perkhidmatan penyenggaraan hartanah. Sebanyak 12,914 rekod data mentah telah diperoleh daripada set data DP, merangkumi 28 atribut, dan melibatkan data bagi tahun 2021.

Tiada sebarang data peribadi pengguna atau ejen dikumpulkan bagi memastikan keselamatan dan kerahsiaan maklumat peribadi. Kesemua data diperoleh dalam format perisian Microsoft Excel.

Sebaik sahaja data mentah ini diterima, aktiviti menganalisis struktur data dibuat. Data ini seterusnya akan melalui proses pra-pemprosesan data bagi mempersiapkan data sebelum proses pengelompokan bermula. Seperti yang ditunjukkan di dalam gambarajah 3.1, proses pra-pemprosesan data melibatkan aktiviti pembersihan data, penjanaan atribut, transformasi data, serta penyaringan atribut.



Rajah 3.1 Rangka kerja analisis dan pra pemrosesan data di dalam fasa penyediaan data.

### 3.2.2 Analisis Struktur Data

Analisis struktur data dilakukan terhadap data mentah penyenaraian hartanah daripada DP. Jadual 3.1 menunjukkan atribut bagi set data.

Jadual 3.1 Senarai Set Data Beserta Atribut

| Set Data          | Atribut                                                                                                                                                                                                                                                                           | Jumlah Data | Jumlah Atribut |
|-------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------|----------------|
| <i>DurianProp</i> | <i>Price, Built_Up_SF, Bathroom, Furnishing, Bedroom, Tenure, Car_Park, Agent_Code, Agent_Name, URL, Desc, Date, Place, Area, Source, Property_Type, Property_Address, Occupancy, Title, Facing, Unit Type, Land Size, Land D1, Land D2, Price_PSF Land, Postcode, Views, src</i> | 12,914      | 28             |

Dapat dilihat daripada jadual 3.1, set data mempunyai 28 dengan 12,914 rekod data. Data kemudiannya terus dianalisis bagi mengetahui format setiap atribut, kuantiti serta kualiti data.

## 3.3 PRA-PEMROSESAN DATA

### 3.3.1 Pembersihan Data Teks

Pra-pemprosesan teks merupakan satu langkah penting dalam pemprosesan bahasa semula jadi (NLP) bagi memastikan data teks berada dalam keadaan bersih, konsisten dan bersedia untuk analisis seterusnya. Dalam kajian ini, pelbagai teknik pra-pemprosesan telah diaplikasikan ke atas data teks hartanah bagi meningkatkan prestasi model. Langkah-langkah yang dilaksanakan adalah seperti berikut:

#### i. Pembuangan URL

Sebarang pautan URL dalam teks telah dibuang bagi menghapuskan rujukan luaran yang tidak menyumbang kepada ciri teks yang bermakna.

#### ii. Pembuangan Sebutan Pengguna (@username)

Sebutan pengguna, yang kebiasaannya wujud dalam media sosial atau set data perbualan, telah disingkirkan kerana ia tidak menyumbang kepada makna kontekstual deskripsi hartanah.

### **iii. Pembuangan Hashtag (#hashtag)**

Hashtag telah dibuang tetapi kandungan teras teks dikekalkan bagi mengekalkan konteks yang bermakna.

### **iv. Penghapusan Tanda Baca dan Aksara Khas**

Semua tanda baca dan aksara khas (contohnya 1, @, #, \$, 8) telah dibuang bagi memastikan perwakilan teks yang seragam.

### **v. Penghapusan Ruang Lebi**

Ruang berlebihan dan jarak tidak perlu antara perkataan telah dibuang untuk menyeragamkan format teks.

### **vi. Pembuangan Perkataan Henti (Stopwords)**

Perkataan henti yang biasa digunakan (contohnya "dan", "adalah", "di", "dengan") telah dibuang menggunakan senarai perkataan henti yang ditetapkan untuk mengurangkan dimensi data teks.

### **vii. Penukaran ke Huruf Kecil**


Kesemua teks telah ditukarkan kepada huruf kecil bagi memastikan konsistensi data. Langkah ini dapat mengelakkan penduaan yang berpunca daripada perbezaan penggunaan huruf besar dan huruf kecil, contohnya perkataan “Rumah” dan “rumah” yang dianggap sebagai entiti yang sama.

### **viii. Pernormalan Aksara**

Penormalan aksara telah dilakukan untuk menukar aksara yang serupa kepada bentuk standarnya. Langkah ini membantu dalam mengurangkan ketidakkonsistenan dalam perwakilan teks.

#### ix. Penjelmaan Token Menggunakan Tokenizer XLNet

Teks yang telah melalui proses pra-pemprosesan seterusnya ditukarkan kepada token menggunakan kaedah tokenisasi XLNet. Proses tokenisasi melibatkan pemecahan teks kepada unit-unit yang lebih kecil, dikenali sebagai token, yang berfungsi sebagai input kepada model. Tokenizer XLNet menggunakan pendekatan subperkataan, yang membolehkan pengendalian perkataan jarang serta menghasilkan perwakilan teks yang lebih bermakna.



Rajah 3.2 Aktiviti pemprosesan data teks



### 3.3.2 Pembersihan Metadata

#### i) Atribut Tiada Nilai

Semakan statistik data mendapati wujudnya beberapa rekod yang tidak mempunyainilai (missing values), atau nilai data adalah 'NA' dan /atau nilai data adalah -1. Di dalam kajian ini, kesemua nilai ini diklasifikasikan sebagai data atau atribut tiada nilai. Jadual 3.2 di bawah menyenaraikan atribut-atribut yang mempunyai nilai data tersebut berserta tindakan yang akan diambil bagi membuat pembersihan.

Jadual 3.2 Senarai atribut yang mengandungi data tiada nilai dan tindakan yang diambil

| Bil. | Atribut           | Bilangan<br>Nilai Data<br>'NA' | Bilangan<br>Nilai Data -1 | Bilangan<br>Data<br>Tiada<br>Nilai | Tindakan                                                              |
|------|-------------------|--------------------------------|---------------------------|------------------------------------|-----------------------------------------------------------------------|
| 1    | <i>Land_D1</i>    |                                | Keseluruhan               |                                    | Dibuang daripada set data                                             |
| 2    | <i>Land_D2</i>    |                                | Keseluruhan               |                                    |                                                                       |
| 3    | <i>Title</i>      |                                | Keseluruhan               |                                    |                                                                       |
| 4    | <i>Facing</i>     |                                | Keseluruhan               |                                    |                                                                       |
| 5    | <i>Postcode</i>   |                                | Keseluruhan               |                                    |                                                                       |
| 6    | <i>Views</i>      |                                | Keseluruhan               |                                    |                                                                       |
| 7    | <i>Agent_Code</i> | 4596                           | -                         | -                                  |                                                                       |
| 8    | <i>Bathroom</i>   | 24                             | -                         | -                                  | Ekstrak data daripada atribut <i>Desc</i> dan ganti nilai atribut ini |
| 9    | <i>Furnishing</i> | 1274                           | -                         |                                    |                                                                       |
| 10   | <i>Tenure</i>     | 210                            | -                         | -                                  |                                                                       |
| 11   | <i>Car_Park</i>   | 3421                           | -                         | -                                  |                                                                       |
| 12   | <i>Occupancy</i>  | 4701                           | -                         | 84                                 |                                                                       |
| 13   | <i>Unit_Type</i>  | 4382                           | -                         | 84                                 |                                                                       |

|    |                      |   |      |    |                                                                                                      |
|----|----------------------|---|------|----|------------------------------------------------------------------------------------------------------|
| 14 | <i>Price_PSFLand</i> | - | 5162 | 84 | Mengganti data dengan nilai atribut <i>Price</i> dibahagikan dengan nilai atribut <i>Build_Up_SF</i> |
| 15 | <i>Land_Size</i>     | - | 5162 | 84 | Mengambil data yang sama daripada atribut <i>Build_Up_SF</i>                                         |

Berdasarkan jadual di atas, dapat diperhatikan bahawa set data ini mengandungi sejumlah besar data yang tidak bernilai. Sebanyak 84 rekod data yang tidak mempunyai nilai bagi kesemua atribut telah dibuang kerana bilangannya adalah kecil. Selain itu, terdapat beberapa atribut yang hanya mengandungi nilai tunggal yang tidak bermakna, iaitu nilai -1 bagi keseluruhan data. Atribut-atribut tersebut telah disingkirkan daripada set data kerana maklumat yang berkaitan tidak dapat diperolehi daripada mana-mana atribut lain. Walau bagaimanapun, terdapat juga atribut lain yang mengandungi nilai tunggal -1 bagi keseluruhan data tetapi tidak dibuang daripada set data kerana maklumat tersebut masih boleh diperolehi melalui atribut lain, seperti atribut Desc. Atribut Desc mengandungi data berbentuk teks yang kaya dengan maklumat tidak berstruktur, justeru proses penerokaan pengetahuan perlu dijalankan bagi mengekstrak maklumat yang diperlukan.

Bagi menggantikan data atribut Car\_Park yang tiada nilai, setiap data jenis kediaman atau Property\_Type akan dianalisis bagi mendapatkan jumlah Car\_Park yang paling kerap (frequent) . Sebagai contoh, data Property\_Type dengan nilai Terrace House, kekerapan nilai Car\_Park adalah 2, justeru atribut Car\_Park yang tiada nilai dan Property\_Type bagi data ini adalah Terrace House, maka nilai 2 dimasukkan kedalam atribut Car\_Park\_new. Kaedah yang sama telah diaplikasikan ke atas atribut Bathroom dan Bedroom yang mengandungi data tiada nilai.

## ii. Atribut Nilai Tunggal

Atribut yang mempunyai satu nilai sahaja akan dikeluarkan daripada set data seperti atribut *Date* yang mengandungi 11/10/2021 (set data DP) serta atribut *Source* yang


memegang nilai Durian (set data DP). Jadual 3.3 menyenaraikan atribut yang mempunyai hanya satu nilai sahaja.

Jadual 3.3 Senarai Atribut Yang Mempunyai Hanya Satu Nilai

| Bil. | Atribut       | Nilai Tunggal   |
|------|---------------|-----------------|
| 1    | <i>Date</i>   | 11/10/2021      |
| 2    | <i>Source</i> | Durian Property |

### iii. Data tidak Relevan

Data yang tidak relevan perlu dikemaskini atau dibersihkan bagi mendapatkan nilai data yang lebih bermakna. Analisis data telah menemukan atribut *Bedroom*, *Bathroom* dan *Car\_Park* mempunyai beberapa nilai data yang tidak relevan seperti gambar rajah 3.3:



Rajah 3.3 Nilai Data Tidak Relevan Bagi Atribut *Bedroom*

Rajah 3.3 menunjukkan bahawa atribut *Bedroom* mengandungi nilai yang tidak relevan bagi kajian ini, seperti 3+1, 1+1, 2+1, dan sebagainya. Proses pembersihan data telah dijalankan dengan membulatkan nilai-nilai tersebut kepada satu nombor tunggal,

contohnya 3+1 ditukarkan kepada 4, manakala 1+1 ditukarkan kepada 2, dan seterusnya. Kaedah yang sama turut diaplikasikan ke atas atribut *Bathroom* dan *Car\_Park*.

#### iv. Penyeragaman Nilai Data

Memastikan konsistensi nilai data merupakan aspek yang amat penting bagi menjamin proses pengkategorian data dapat dilaksanakan dengan tepat. Ketidakteraturan nilai data boleh berlaku dalam pelbagai bentuk, seperti perbezaan penggunaan huruf besar dan kecil, ketidakteraturan ejaan, perbezaan maksud nilai, serta ketidakteraturan format data. Walau bagaimanapun, atribut ini mengandungi data yang sangat tidak berstruktur, menyebabkan wujudnya pelbagai maklumat dengan nilai data yang tidak seragam. Setelah maklumat diekstrak daripada atribut *Desc* dan dimasukkan ke dalam atribut yang mempunyai nilai tiada, proses penyeragaman nilai data perlu dijalankan.

Bagi atribut *Furnishing*, ia memegang nilai '*Partial Furnished*', '*Fully Furnished*' dan '*Unfurnished*'. Nilai-nilai data ini tidak mempunyai keseragaman seperti yang ditunjukkan di dalam jadual 3.4 :

| Jadual 3.4 Nilai Data Tidak Seragam bagi Atribut <i>Furnishing</i> |                               |                                 |
|--------------------------------------------------------------------|-------------------------------|---------------------------------|
| Bil.                                                               | Nilai Data Yang Tidak Seragam | Nilai Data Setelah Penyeragaman |
| 1                                                                  | Fully furnished               | Fully Furnished                 |
| 2                                                                  | FULLY FURNISHED               |                                 |
| 3                                                                  | Fully Furnished               |                                 |
| 4                                                                  | semi furnished                | Partly Furnished                |
| 5                                                                  | Partially furnished           |                                 |
| 6                                                                  | partly furnished              |                                 |
| 7                                                                  | Partially Furnished           |                                 |
| 8                                                                  | SEMI FURNISHED                |                                 |
| 9                                                                  | SEMI furnished                |                                 |
| 10                                                                 | unfurnished                   | Unfurnished                     |
| 11                                                                 | UNFURNISHED                   |                                 |

Atribut Occupancy yang memegang nilai ‘Owner Occupied’, ‘Vacant’ dan ‘Tenanted’ juga mempunyai nilai data yang tidak seragam. Jadual 3.5 menunjukkan nilai data tidak seragam bagi atribut *Occupancy* dengan lebih jelas.

| Jadual 3.5 Nilai Data Tidak Seragam bagi Atribut <i>Occupancy</i> |                               |                                 |
|-------------------------------------------------------------------|-------------------------------|---------------------------------|
| Bil.                                                              | Nilai Data Yang Tidak Seragam | Nilai Data Setelah Penyeragaman |
| 1                                                                 | Occupied                      | Owner Occupied                  |
| 2                                                                 | occupied                      |                                 |
| 3                                                                 | OCCUPIED                      |                                 |
| 4                                                                 | vacant                        | Vacant                          |
| 5                                                                 | VACANT                        |                                 |
| 6                                                                 | unoccupied                    |                                 |
| 7                                                                 | UNOCCUPIED                    |                                 |
| 8                                                                 | tenanted                      | Tenanted                        |
| 9                                                                 | TENANTED                      |                                 |

Bagi atribut *Unit\_Type* pula, penyeragaman nilai data akan dibuat bagi mendapatkan nilai ‘Intermediate Lot’, ‘Corner Lot’ dan ‘End Lot’ yang seragam seperti yang telah diperincikan di Jadual 3.6 di bawah:

| Jadual 3.6 Nilai Data Tidak Seragam bagi Atribut <i>Unit_Type</i> |                               |                                 |
|-------------------------------------------------------------------|-------------------------------|---------------------------------|
| Bil.                                                              | Nilai Data Yang Tidak Seragam | Nilai Data Setelah Penyeragaman |
| 1                                                                 | Intermediate lot              | Intermediate Lot                |
| 2                                                                 | intermediate lot              |                                 |
| 3                                                                 | INTERMEDIATE LOT              |                                 |
| 4                                                                 | Intermediate Lot              |                                 |
| 5                                                                 | Corner lot                    | Corner Lot                      |
| 6                                                                 | corner lot                    |                                 |
| 7                                                                 | CORNER LOT                    |                                 |
| 8                                                                 | Corner lot                    |                                 |

|    |            |         |
|----|------------|---------|
| 9  | Corner Lot |         |
| 10 | End Lot    | End Lot |
| 11 | end lot    |         |
| 12 | END LOT    |         |
| 13 | END LOT    |         |

Atribut *Tenure* juga telah dibuat penyeragaman seperti yang dijelaskan didalam Jadual 3.7 dibawah :

| Jadual 3.7 Nilai Data Tidak Seragam bagi Atribut <i>Tenure</i> |                               |                                 |
|----------------------------------------------------------------|-------------------------------|---------------------------------|
| Bil.                                                           | Nilai Data Yang Tidak Seragam | Nilai Data Setelah Penyeragaman |
| 1                                                              | <i>freehold</i>               | Freehold                        |
| 2                                                              | <i>FREEHOLD</i>               |                                 |
| 3                                                              | <i>Free</i>                   |                                 |
| 4                                                              | <i>FREE</i>                   |                                 |
| 5                                                              | <i>free</i>                   |                                 |
| 6                                                              | Leasehold                     | Leasedhold                      |

Atribut *Property\_Type* mempunyai 19 nilai data yang pelbagai, namun beberapa nilai data mempunyai maksud yang sama walaupun nama yang berbeza. Operator ‘*Map*’ akan diaplikasikan keatas atribut *Property\_Type* bagi menyeragamkan nilai data seperti yang ditunjukkan di Jadual 3.8 dan nilai data terkini adalah sebanyak 10.

| Jadual 3.8 Nilai Data Tidak Seragam bagi Atribut <i>Property_Type</i> |                               |                                     |
|-----------------------------------------------------------------------|-------------------------------|-------------------------------------|
| Bil.                                                                  | Nilai Data Yang Tidak Seragam | Nilai Data Setelah Penyeragaman     |
| 1                                                                     | Town House                    | Townhouse                           |
| 2                                                                     | Cluster House                 | Cluster                             |
| 3                                                                     | House (Others)                | Terrace House                       |
| 4                                                                     | Link Bungalow                 | Link Bungalow / Semi-Detached House |
| 5                                                                     | Link Villa                    | Bungalow / Detached House / Villa   |

|    |                   |                                              |
|----|-------------------|----------------------------------------------|
| 6  | Villa             | Bungalow / Detached House / Villa            |
| 7  | Service Residence | Condominium / Apartment / Serviced Residence |
| 8  | Condo             | Condominium / Apartment / Serviced Residence |
| 9  | Apartment         | Condominium / Apartment / Serviced Residence |
| 10 | Semi D            | Link Bungalow / Semi-Detached House          |

### 3.3.3 Transformasi Data

#### i. Transformasi Jenis Data Nominal Kepada Numerikal

Kebanyakan model pembelajaran mesin memerlukan semua pembolehubah input dan output berada dalam bentuk numerik. Oleh itu, semua atribut yang mengandungi pembolehubah bersifat kategorikal atau nominal perlu melalui proses pemetaan atau pengekodan kepada nilai berangka sebelum dimasukkan ke dalam model. Dalam kajian ini, pengekodan integer telah diaplikasikan ke atas set data hartanah, di mana setiap nilai kategori yang unik ditukarkan kepada nilai integer tersendiri. Jadual 3.9 menyenaraikan atribut yang terlibat berserta jenis data secara ringkas, manakala senarai penuh data perwakilan disertakan dalam Lampiran A.

Jadual 3.9 Senarai Atribut Norminal Dengan Perwakilan Dan Jenis Data

| Jadual 3.9 Senarai Atribut Norminal Dengan Perwakilan Dan Jenis Data |                   |                  |             |
|----------------------------------------------------------------------|-------------------|------------------|-------------|
| Bil.                                                                 | Atribut           | Nilai            | Kod Integer |
| 1.                                                                   | <i>Furnishing</i> | Unknown          | 0           |
|                                                                      |                   | Partly Furnished | 1           |
|                                                                      |                   | Unfurnished      | 2           |
|                                                                      |                   | Fully Furnished  | 3           |
| 2.                                                                   | <i>Tenure</i>     | Unknown          | 0           |
|                                                                      |                   | Leasedhold       | 1           |

|    |                      |                                             |    |
|----|----------------------|---------------------------------------------|----|
|    |                      | Freehold                                    | 2  |
| 3. | <i>Property_Type</i> | Unknown                                     | 0  |
|    |                      | Terrace House                               | 1  |
|    |                      | Link Bungalow / Semi-Detached House         | 2  |
|    |                      | Condominium / Apartment/ Serviced Residence | 3  |
|    |                      | Flat                                        | 4  |
|    |                      | Bungalow / Detached House / Villa           | 5  |
|    |                      | Townhouse                                   | 6  |
|    |                      | Cluster                                     | 7  |
|    |                      | Low-Cost House                              | 8  |
|    |                      | Superlink                                   | 9  |
|    |                      | Penthouse                                   | 10 |
|    |                      | Commercial / Non-Residential                | 11 |
|    |                      | Land                                        | 12 |
| 4. | <i>Occupancy</i>     | Unknown                                     | 0  |
|    |                      | Vacant                                      | 1  |
|    |                      | Tenanted                                    | 2  |
|    |                      | Owner Occupied                              | 3  |
|    |                      | Unoccupied                                  | 4  |
| 5. | <i>Unit_Type</i>     | Unknown                                     | 0  |
|    |                      | Intermediate Lot                            | 1  |
|    |                      | Corner Lot                                  | 2  |
|    |                      | End Lot                                     | 3  |

---

### 3.3.4 Pemilihan Atribut

Pemilihan atribut adalah proses mengurangi bilangan pembolehubah input. Proses ini dapat mengurangi masa proses pengelasan. Di dalam kajian ini, Berdasarkan perhatian, terdapat atribut yang tidak berkepentingan yang perlu dibuang secara manual



iaitu atribut *Views* and *Postcode*. Atribut ini tidak diperlukan bagi proses seterusnya memandangkan ia tidak mengandungi maklumat yang penting dalam ramalan data.

### 3.3.5 Geokodan Dan Kejuruteraan Ciri

Dalam fasa ini, proses geocoding dilaksanakan sebagai sebahagian daripada data preprocessing untuk memperkayakan set data hartanah dengan maklumat geospasial. Memandangkan set data asal tidak menyediakan koordinat geografi secara langsung, atribut *Place* dan *Area* digunakan untuk menjana koordinat latitude dan longitude bagi setiap lokasi hartanah. Proses ini melibatkan penukaran maklumat lokasi berasaskan teks kepada koordinat geografi yang boleh digunakan untuk analisis spasial.

Koordinat yang diperoleh seterusnya digunakan dalam proses *feature engineering* bagi menghasilkan ciri-ciri geospasial baharu yang relevan, seperti jarak relatif antara hartanah dan kawasan sekitarnya. Ciri-ciri ini penting kerana faktor lokasi dan aksesibiliti mempunyai pengaruh yang signifikan terhadap nilai dan harga hartanah. Dengan penambahan ciri geospasial ini, model pembelajaran mesin dapat memahami hubungan spasial dengan lebih baik dan seterusnya meningkatkan ketepatan ramalan harga.

Walaupun koordinat yang dijana mewakili titik pusat kawasan dan bukan lokasi tepat setiap unit hartanah, pendekatan ini masih sesuai untuk tujuan analisis dan pemodelan pada peringkat kawasan. Proses geocoding dan feature engineering ini membantu menyediakan set data yang lebih lengkap dan bermakna sebelum fasa latihan model pembelajaran mesin dijalankan. Jadual 3.10 menyenaraikan atribut geospasial dan atribut baharu yang terhasil daripada proses geokodan dan kejuruteraan ciri yang digunakan dalam kajian ini.

Jadual 3.10 Senarai atribut geospasial dan atribut baharu yang terhasil

| Bil. | Area                    | Place     | Latitude | Longitude  |
|------|-------------------------|-----------|----------|------------|
| 1    | Taman Sri Kenari        | Kajang    | 2.991804 | 101.769137 |
| 2    | Taman Sentosa           | Klang     | 3.009219 | 101.467582 |
| 3    | Bandar Pinggiran Subang | Shah Alam | 3.159791 | 101.549091 |
| 4    | Pusat Bandar Rawang     | Rawang    | 3.31838  | 101.578148 |

|   |                     |               |          |            |
|---|---------------------|---------------|----------|------------|
| 5 | Dataran Otomobil    | Shah Alam     | 3.064166 | 101.532735 |
| 6 | Desa Mentari        | Petaling Jaya | 3.079608 | 101.617548 |
| 7 | Kuala Lumpur        | Malaysia      | 3.047918 | 101.689247 |
| 8 | Taman Puchong Utama | Puchong       | 2.986089 | 101.614853 |

### 3.3.6 Set Data Akhir

Jadual 3.11 menunjukkan senarai data akhir yang terpilih selepas kesemua pra-pemrosesan data dibuat. Set data akhir ini secara keseluruhannya mengandungi .. atribut termasuk atribut id dengan bilangan data sebanyak 5,981 rekod.

Jadual 3.11 Senarai Set Data Akhir

| Set Data          | Atribut                                                                                                                                                                                                                       | Jumlah Data | Jumlah Atribut |
|-------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------|----------------|
| <i>DurianProp</i> | <i>Price, Built_Up_SF, Bathroom, Furnishing, Bedroom, Tenure, Car_Park, Agent_Name, Desc, Place, Area, Property_Type, Property_Address, Occupancy, Unit Type, Land Size, Price_PSFLand, full_address, Longitude, Latitude</i> | 5,981       | 20             |

## 3.4 ANALISIS DESKRIPTIF

Selepas proses pra-pemrosesan dan pemilihan atribut dijalankan, analisis deskriptif dilaksanakan bagi memahami taburan dan corak data yang digunakan dalam kajian ini. Dataset yang digunakan mengandungi sebanyak 5,981 rekod hartanah, yang terdiri daripada beberapa atribut numerikal utama seperti harga hartanah, saiz binaan, keluasan tanah, bilangan bilik tidur, bilik air dan tempat letak kenderaan. Statistik deskriptif yang meliputi nilai minimum, maksimum dan purata telah diringkaskan dalam Jadual 3.12.


Dalam kajian ini, setiap atribut dalam dataset telah melalui kaedah pra-pemrosesan yang berbeza bergantung kepada jenis data dan peranannya dalam sistem penilaian hartanah yang dibangunkan. Pendekatan ini bertujuan untuk memastikan kualiti data yang tinggi serta meningkatkan ketepatan fungsi carian dan modul ramalan harga dalam sistem.

Bagi atribut harga hartanah (*Price*), saiz binaan (*Built\_Up\_SF*) dan keluasan tanah (*Land\_Size*), kaedah Interquartile Range (IQR) telah digunakan untuk mengenal pasti dan menyingkirkan nilai luar biasa (outlier). Kaedah ini dipilih kerana atribut-atribut tersebut merupakan data berterusan dan mudah dipengaruhi oleh nilai ekstrem yang boleh menjejaskan taburan data serta prestasi model ramalan.

Atribut bilangan bilik tidur (*Bedroom*) pula dikendalikan menggunakan pendekatan rule-based. Pendekatan ini menetapkan julat nilai yang munasabah berdasarkan ciri tipikal hartanah kediaman, di mana nilai sifar dikekalkan bagi mewakili unit studio manakala nilai yang berada di luar julat realistik disingkirkan daripada dataset.


Bagi atribut *Latitude* dan *Longitude*, kaedah range validation telah digunakan untuk memastikan semua koordinat geografi berada dalam julat lokasi yang sah di Malaysia. Rekod yang mempunyai nilai koordinat di luar julat tersebut atau tidak lengkap dikenal pasti sebagai tidak sah dan dikeluarkan bagi mengelakkan kesilapan dalam analisis berasaskan lokasi.

Selain itu, pengendalian nilai hilang (*missing values*) dilaksanakan sama ada melalui penyingkiran rekod atau pengisian semula (*imputation*), bergantung kepada kepentingan atribut tersebut terhadap fungsi sistem. Pendekatan ini memastikan dataset akhir yang digunakan dalam fasa seterusnya adalah lebih konsisten, seimbang dan mewakili keadaan sebenar pasaran hartanah.




Rajah 3.4 Graf Histogram Perbandingan Taburan Data *Price* sebelum dan Selepas Pembersihan

Histogram ini menunjukkan taburan harga hartanah sebelum proses pembersihan data dijalankan. Taburan data adalah sangat condong ke kanan, dengan sebahagian besar rekod tertumpu pada julat harga yang rendah, manakala terdapat beberapa nilai ekstrem yang sangat tinggi. Kehadiran nilai harga yang melampau ini menyebabkan taburan data menjadi tidak seimbang dan menyukarkan pemerhatian corak sebenar harga hartanah. Histogram ini menunjukkan taburan harga hartanah selepas proses pembersihan data menggunakan kaedah Interquartile Range (IQR). Nilai ekstrem yang sebelum ini mendominasi taburan telah disingkirkan, menghasilkan taburan data yang lebih seimbang dan jelas. Julat harga yang dipaparkan juga lebih munasabah dan mencerminkan keadaan sebenar pasaran hartanah kediaman.



Rajah 3.5 Graf Histogram Perbandingan Taburan Data *Land\_Size* sebelum dan Selepas Pembersihan

Histogram ini menggambarkan taburan keluasan tanah sebelum pembersihan data dijalankan. Taburan data menunjukkan kehadiran nilai yang sangat besar dan tidak realistik, menyebabkan sebahagian besar data tertumpu pada bahagian awal graf. Keadaan ini menunjukkan kewujudan nilai luar biasa yang berpotensi menjejaskan analisis dan pemodelan seterusnya. Histogram ini menunjukkan taburan keluasan tanah selepas proses pembersihan menggunakan kaedah IQR. Selepas nilai ekstrem disingkirkan, taburan data menjadi lebih seimbang dan julat nilai yang dipaparkan adalah lebih realistik. Corak taburan yang terhasil mencerminkan ciri tipikal keluasan tanah bagi hartanah kediaman.



Rajah 3.6 Box Plot Perbandingan Taburan Data *Price* sebelum dan Selepas Pembersihan

Box plot ini menunjukkan taburan harga hartanah sebelum pembersihan data. Sebilangan besar nilai luar biasa dapat diperhatikan berada jauh di luar julat interkuartil, menandakan kewujudan nilai harga yang melampau. Kehadiran outlier ini boleh mempengaruhi nilai purata serta menjejaskan kestabilan model ramalan. Box plot ini menunjukkan taburan harga hartanah selepas proses pembersihan data dijalankan. Bilangan nilai luar biasa berkurangan dengan ketara dan julat interkuartil menjadi lebih padat. Nilai median yang diperoleh adalah lebih representatif terhadap keseluruhan dataset, menandakan bahawa data yang digunakan adalah lebih stabil dan sesuai untuk pemodelan ramalan harga.

Secara keseluruhannya, strategi pra-pemprosesan data ini membolehkan sistem menggunakan data yang lebih bersih dan boleh dipercayai, sekali gus meningkatkan kebolehpercayaan serta ketepatan output yang dihasilkan oleh sistem penilaian hartanah.

Jadual 3.12 Analisis data Deskriptif

|                             | <b>count</b> | <b>mean</b> | <b>std</b> | <b>min</b> | <b>25%</b>  | <b>50%</b> | <b>75%</b> | <b>max</b> |
|-----------------------------|--------------|-------------|------------|------------|-------------|------------|------------|------------|
| <b><i>Price</i></b>         | 5981         | 470248.848  | 226822.650 | 51500      | 300000      | 430000     | 58800      | 1571700    |
| <b><i>Built_Up_SF</i></b>   | 5981         | 1391.884    | 599.147    | 153        | 926         | 1283       | 1760       | 3600       |
| <b><i>Bathroom</i></b>      | 5981         | 2.484       | 0.813      | 1          | 2           | 2          | 3          | 5          |
| <b><i>Furnishing</i></b>    | 5981         | 1.755       | 0.658      | 1          | 1           | 2          | 2          | 3          |
| <b><i>Bedroom</i></b>       | 5981         | 3.008       | 1.243      | 0          | 3           | 3          | 4          | 10         |
| <b><i>Tenure</i></b>        | 5981         | 1.568       | 0.536      | 0          | 1           | 2          | 2          | 2          |
| <b><i>Car_Park</i></b>      | 5981         | 1.740       | 0.670      | 0          | 1           | 2          | 2          | 5          |
| <b><i>Property_Type</i></b> | 5967         | 2.548       | 2.184      | 1          | 1           | 3          | 3          | 12         |
| <b><i>Occupancy</i></b>     | 5435         | 0.570       | 0.694      | 0          | 0           | 0          | 1          | 2          |
| <b><i>Unit_Type</i></b>     | 5981         | 0.730       | 0.803      | 0          | 0           | 1          | 1          | 3          |
| <b><i>Land_Size</i></b>     | 5981         | 1292.272    | 458.883    | 226        | 938         | 1300       | 1540       | 2680       |
| <b><i>Price_PSF</i></b>     | 5981         | 371.026     | 131.040    | 36.786     | 280         | 357.143    | 450        | 745.455    |
| <b><i>Latitude</i></b>      | 5981         | 3.144       | 0.822      | 1.408      | 2.9572206   | 3.067      | 3.181      | 6.529      |
| <b><i>Longitude</i></b>     | 5981         | 101.787     | 1.126      | 100.231    | 101.5467025 | 101.672    | 101.773    | 118.010    |

### 3.5 RUMUSAN

Bab ini telah membincangkan secara terperinci analisis data dan spesifikasi keperluan yang digunakan dalam pembangunan sistem Smart Property Valuer. Perbincangan bermula dengan pengenalan kepada keperluan data, diikuti oleh analisis struktur set data hartanah yang diperoleh daripada sumber penyenaraian hartanah tempatan. Analisis ini penting bagi memahami ciri-ciri data, kualiti data serta isu-isu yang berpotensi menjejaskan ketepatan model ramalan.

Seterusnya, bab ini menghuraikan proses pra-pemprosesan data yang merangkumi pembersihan data teks dan metadata, pengendalian nilai tiada dan nilai tidak relevan, penyeragaman nilai data, serta transformasi data kategorikal kepada bentuk numerik. Proses pengkodan dan pemilihan atribut telah dilaksanakan bagi memastikan hanya ciri-ciri yang signifikan digunakan dalam latihan model pembelajaran mesin. Di samping itu, kejuruteraan ciri geospasial melalui proses geokodan telah dijalankan bagi memperkayakan set data dengan maklumat lokasi yang relevan.

Bab ini juga membincangkan analisis deskriptif yang dilaksanakan untuk memahami taburan dan corak data selepas proses pra-pemprosesan. Pendekatan seperti pengendalian nilai luar biasa dan pengesanan julat data telah digunakan bagi meningkatkan kualiti dan kebolehpercayaan set data akhir. Hasil daripada keseluruhan proses ini ialah satu set data yang bersih, konsisten dan bersedia untuk digunakan dalam fasa latihan dan penilaian model.

Secara keseluruhannya, Bab III memainkan peranan penting dalam memastikan asas data yang kukuh bagi pembangunan sistem Smart Property Valuer. Keberkesanan proses pra-pemprosesan dan analisis data yang dilaksanakan dalam bab ini secara langsung mempengaruhi ketepatan dan kebolehpercayaan model ramalan harga hartanah yang akan dibincangkan dalam Bab IV.

## **BAB IV**

### **SPESIFIKASI REKA BENTUK DAN PENILAIAN**

#### **4.1 PENGENALAN**

Bab ini menerangkan spesifikasi reka bentuk sistem serta pendekatan penilaian yang digunakan dalam pembangunan sistem Smart Property Valuer. Bab ini memberi tumpuan kepada pemilihan algoritma pembelajaran mesin, reka bentuk seni bina sistem, strategi eksperimen, serta kaedah penilaian prestasi bagi memastikan sistem yang dibangunkan mampu menghasilkan ramalan harga hartanah yang tepat dan cadangan hartanah yang relevan.

Perbincangan dimulakan dengan justifikasi pemilihan algoritma Random Forest Regression dan XGBoost Regression sebagai model ramalan harga hartanah, berdasarkan kesesuaian kedua-dua algoritma ini terhadap data hartanah yang bersifat tabular dan tidak linear. Selain itu, kaedah cosine similarity turut digunakan dalam modul cadangan hartanah bagi mengenal pasti hartanah yang paling hampir dengan keperluan dan pilihan pengguna.

Bab ini juga menghuraikan seni bina model dan sistem secara menyeluruh, merangkumi aliran data daripada proses pra-pemprosesan dan geokodan sehingga kepada penghasilan output dalam bentuk harga ramalan dan senarai cadangan hartanah melalui aplikasi web berasaskan Flask. Strategi eksperimen yang digunakan, termasuk pembahagian data dan penalaan hiperparameter, turut dibincangkan bagi memastikan kebolehan generalisasi model yang baik.

Akhir sekali, bab ini menerangkan kaedah penilaian prestasi menggunakan metrik seperti Mean Absolute Error (MAE), Root Mean Squared Error (RMSE) dan Coefficient of Determination ( $R^2$ ), serta spesifikasi keperluan fungsian, perkakasan dan



perisian sistem. Perbincangan ini bertujuan untuk memastikan sistem Smart Property Valuer dibangunkan secara sistematik, berprestasi tinggi dan bersesuaian untuk digunakan sebagai alat sokongan keputusan dalam pasaran hartanah Malaysia.

#### **4.2 PEMILIHAN ALGORITMA DAN JUSTIFIKASI**

Seksyen ini menerangkan secara terperinci pemilihan model pembelajaran mesin yang digunakan dalam sistem Smart Property Valuer, termasuk justifikasi pemilihan algoritma, hubungan model dengan seni bina sistem, serta sokongan daripada kajian dan dokumentasi terdahulu. Pemilihan model yang sesuai adalah penting bagi memastikan sistem dapat menghasilkan ramalan harga hartanah yang tepat dan cadangan yang relevan kepada pengguna.

Sistem Smart Property Valuer direka bentuk sebagai satu sistem bersepadu yang terdiri daripada beberapa modul utama, iaitu modul prapemprosesan dan geokodan, modul ramalan harga hartanah, serta modul cadangan hartanah. Modul-modul ini saling berkaitan dan berfungsi secara berurutan bermula daripada input pengguna sehingga paparan output akhir dalam bentuk harga ramalan dan senarai hartanah yang dicadangkan. Pendekatan ini membolehkan sistem menyokong proses membuat keputusan pengguna dengan lebih sistematik dan berasaskan data.

Dalam sistem ini, pengguna akan memasukkan maklumat berkaitan hartanah seperti jenis rumah, saiz, bilangan bilik, lokasi dan lain lain. Walau bagaimanapun, proses geokodan tidak dilaksanakan secara langsung semasa input pengguna, sebaliknya dijalankan lebih awal pada peringkat prapemprosesan dataset asal. Memandangkan set data asal tidak menyediakan maklumat koordinat geografi, atribut *Place* dan *Area* telah digunakan untuk menjana koordinat latitud dan longitud bagi setiap lokasi hartanah.

Proses geokodan ini bertujuan untuk memperkayakan set data dengan maklumat geospatial yang diperlukan bagi analisis lanjut, khususnya untuk pengiraan jarak antara hartanah dan kemudahan berhampiran seperti hospital, stesen pengangkutan awam dan kemudahan awam lain. Setelah proses geokodan dan kejuruteraan ciri selesai, satu set data yang lengkap dan terstruktur akan dihasilkan dan digunakan dalam proses latihan model pembelajaran mesin.

Koordinat geospasial yang telah dijana kemudiannya digunakan sebagai sebahagian daripada ciri input (fitur) kepada model ramalan harga hartanah. Pendekatan ini membolehkan faktor lokasi diambil kira secara kuantitatif dalam proses pemodelan, memandangkan lokasi mempunyai pengaruh yang signifikan terhadap nilai dan harga hartanah.

Bagi modul ramalan harga hartanah, dua algoritma pembelajaran mesin dipilih, iaitu *Random Forest Regression* dan *XGBoost Regression*. Pemilihan kedua-dua algoritma ini dibuat berdasarkan sifat data hartanah yang bersifat tabular serta mempunyai hubungan yang kompleks dan tidak linear antara pembolehubah seperti keluasan rumah, bilangan bilik, jenis hartanah dan lokasi. Random Forest merupakan kaedah ensemble yang membina banyak pokok keputusan dan menggabungkan hasilnya untuk menghasilkan ramalan yang lebih stabil serta kurang sensitif terhadap hingar (noise) dalam data. Menurut dokumentasi rasmi Scikit-learn, Random Forest sesuai digunakan untuk masalah regresi yang melibatkan data tabular dan hubungan tidak linear antara ciri-ciri input.

Selain itu, XGBoost dipilih sebagai model lanjutan kerana keupayaannya untuk mengoptimumkan prestasi ramalan melalui teknik gradient boosting. XGBoost membina model secara berperingkat dengan memberi penekanan kepada kesilapan ramalan terdahulu, sekali gus meningkatkan ketepatan model. Kajian terdahulu menunjukkan bahawa XGBoost sering mencapai prestasi yang lebih baik berbanding kaedah regresi tradisional dalam masalah ramalan harga hartanah, terutamanya apabila melibatkan set data yang besar dan kompleks. Oleh itu, penggunaan kedua-dua model ini membolehkan perbandingan prestasi dibuat dan model terbaik dipilih berdasarkan metrik penilaian yang ditetapkan.

Bagi modul cadangan hartanah pula, kaedah cosine similarity digunakan untuk mengenal pasti hartanah yang paling serupa dengan keperluan dan pilihan pengguna. Kaedah ini mengukur tahap keserupaan antara vektor ciri hartanah berdasarkan sudut kosinus, dan sering digunakan dalam sistem cadangan berasaskan kandungan (content-based recommendation). Dalam konteks sistem Smart Property Valuer, cosine similarity digunakan untuk memadankan hartanah berdasarkan ciri seperti harga

ramalan, saiz, jenis hartanah dan lokasi, seterusnya memaparkan senarai cadangan yang paling relevan kepada pengguna.

Keseluruhan reka bentuk model dan modul ini diintegrasikan dalam aplikasi web berasaskan Flask, manakala data hartanah disimpan dalam pangkalan data MySQL. Reka bentuk ini memastikan aliran data daripada input pengguna, pemprosesan, ramalan dan cadangan dapat dilakukan secara lancar dan teratur. Dengan gabungan modul geokodan, model ramalan harga berasaskan Random Forest dan XGBoost, serta modul cadangan menggunakan cosine similarity, sistem Smart Property Valuer mampu menyediakan sokongan keputusan yang lebih tepat, telus dan berinformasi kepada pengguna dalam pasaran hartanah Malaysia.

#### **4.2.1 Pemilihan Algoritma**


##### **a. Random Forest Regression**

Random Forest merupakan algoritma pembelajaran mesin berasaskan ensemble learning, yang membina pelbagai model Decision Tree secara rawak dan menggabungkan hasil ramalan daripada semua pokok keputusan tersebut untuk menghasilkan satu keputusan akhir. Dalam konteks masalah regresi, seperti ramalan harga rumah, nilai ramalan akhir diperoleh melalui purata ramalan semua pokok keputusan dalam hutan (forest). Pendekatan ini menjadikan Random Forest lebih stabil berbanding penggunaan satu Decision Tree sahaja, kerana kesilapan atau bias pada satu pokok dapat dikurangkan melalui penggabungan hasil daripada pokok-pokok lain.

Pemilihan Random Forest dalam kajian ini adalah selari dengan dapatan kajian lepas yang menunjukkan keberkesanan algoritma ini dalam masalah ramalan harga hartanah. Kajian oleh Schuerch (2023) yang dibincangkan dalam artikel “Beginner’s Guide to Predicting House Prices with Random Forest” menunjukkan bahawa Random Forest mampu menghasilkan prestasi ramalan yang baik dalam masalah regresi harga rumah, khususnya apabila data mengandungi pelbagai ciri seperti bilangan bilik, keluasan, dan jenis kediaman. Kajian tersebut turut menekankan kelebihan Random Forest dalam mengendalikan data kategori yang telah melalui proses pengekodan, serta ketahanannya terhadap data yang tidak seimbang. Selain itu, kajian akademik yang diterbitkan dalam *Procedia Computer Science* (ScienceDirect) turut menggunakan

pendekatan berasaskan ensemble seperti Random Forest bagi meramalkan harga hartanah. Kajian tersebut mendapati bahawa Random Forest memberikan nilai ralat yang lebih rendah berbanding model regresi tradisional, terutamanya apabila set data mengandungi pelbagai faktor yang mempengaruhi harga rumah seperti lokasi, jenis hartanah dan ciri fizikal bangunan. Tambahan pula, kertas kerja daripada ITM Conferences (2025) menunjukkan bahawa model berasaskan pokok keputusan dan ensemble adalah sesuai digunakan untuk data hartanah kerana ia tidak memerlukan andaian linear seperti model regresi linear. Ini menjadikan Random Forest lebih fleksibel dan sesuai untuk data dunia sebenar yang kompleks dan tidak linear.

Berdasarkan kajian-kajian lepas ini, Random Forest dipilih kerana keupayaannya mengendalikan data berstruktur dengan baik, ketahanan terhadap masalah overfitting, prestasi yang konsisten dalam kajian ramalan harga rumah dan tidak memerlukan proses penalaan parameter yang terlalu kompleks. Rajah 4.1 menunjukkan struktur asas dan aliran kerja model Random Forest yang digunakan dalam kajian ini.



Rajah 4.1 Konsep Random Forest Regression

Dalam konteks sistem yang dibangunkan dalam kajian ini, Random Forest berfungsi sebagai teras kepada modul ramalan harga hartanah. Data yang telah melalui proses pembersihan, penyeragaman, pengekodan dan geokodan akan dijadikan input kepada model Random Forest untuk menghasilkan anggaran harga rumah.

Model ini direka bentuk supaya boleh diintegrasikan dengan sistem analisis data atau sistem sokongan keputusan, di mana pengguna boleh memasukkan maklumat berkaitan hartanah dan memperoleh anggaran harga secara automatik. Dengan menggunakan Random Forest, sistem ini mampu memberikan ramalan yang stabil dan boleh dipercayai, sekaligus menyokong proses membuat keputusan berkaitan penilaian hartanah.


#### **b. Xgboost Regression**

Extreme Gradient Boosting (XGBoost), yang dibangunkan oleh Chen dan Guestrin, merupakan satu kaedah pembelajaran mesin berasaskan ensemble yang direka bentuk untuk meningkatkan prestasi model Gradient Boosting Machine (GBM) konvensional dari segi kecekapan pengiraan, kestabilan model serta kebolehan mengendalikan pelbagai fungsi kehilangan dan jenis data input (Chen & Guestrin, 2016). Dalam konteks sistem Smart Property Valuer, XGBoost dipilih sebagai model lanjutan bagi meningkatkan ketepatan ramalan harga hartanah yang melibatkan data tabular berskala besar dan hubungan tidak linear antara ciri-ciri input.

XGBoost beroperasi secara iteratif dengan membina rangkaian model asas, lazimnya dalam bentuk pokok keputusan bersaiz kecil, secara berturutan. Setiap model baharu dibina dengan objektif untuk membetulkan ralat ramalan yang dihasilkan oleh model sebelumnya melalui proses pengoptimuman fungsi kehilangan. Dalam kajian ini, proses latihan bermula dengan set data hartanah yang telah melalui fasa prapemprosesan, termasuk pembersihan data, penyeragaman nilai, geokodan serta kejuruteraan ciri. Set data lengkap ini kemudiannya digunakan sebagai input kepada model XGBoost.

Pada setiap iterasi, proses ini dimulakan dengan set data asal yang dipecahkan kepada subset seperti  $D_1$ ,  $D_2$  hingga  $D_n$ . Setiap subset ini digunakan untuk melatih satu pokok keputusan yang menjana ramalan awal ( $W_1$ ,  $W_2$ , ...,  $W_n$ ). Residual atau ralat daripada setiap ramalan dikira dan digunakan oleh pokok seterusnya untuk mengurangkan kesilapan tersebut. Proses ini diteruskan secara iteratif sehingga model mencapai prestasi yang optimum atau memenuhi kriteria pemberhentian awal (Ibrahim et al. 2021).

Model XGBoost akan mengira ralat atau residual antara nilai harga sebenar dan nilai harga yang diramalkan. Maklumat ralat ini digunakan untuk melatih pokok keputusan seterusnya supaya kesilapan ramalan dapat diminimumkan secara berperingkat. Proses ini diteruskan sehingga bilangan pokok yang ditetapkan dicapai atau kriteria pemberhentian awal dipenuhi, bagi mengelakkan pembinaan model yang terlalu kompleks dan berisiko overfitting. Ramalan harga akhir diperoleh melalui proses penjumlahan sumbangan daripada semua pokok keputusan yang dibina sepanjang proses latihan. Justeru itu, Rajah 4.2 memperlihatkan binaan model XGBoost yang berperingkat dan berstruktur.



Rajah 4.2 Struktur pemodelan XGBoost yang berperingkat

Dalam sistem Smart Property Valuer, penggunaan XGBoost adalah sesuai kerana data hartanah bersifat tabular dan merangkumi gabungan ciri numerikal,

kategori serta geospasial. Berbanding model pembelajaran mendalam yang memerlukan transformasi input yang kompleks, XGBoost mampu mengendalikan data tabular dengan cekap serta memodelkan hubungan tidak linear antara faktor seperti keluasan rumah, bilangan bilik, jenis hartanah dan lokasi yang mempengaruhi harga hartanah.

Kajian terdahulu turut menyokong keberkesanan XGBoost dalam ramalan harga hartanah. Chen dan Guestrin (2016) memperkenalkan XGBoost sebagai model gradient boosting yang cekap dan berprestasi tinggi, manakala kajian oleh Bhushan Jha et al. (2020) menunjukkan bahawa XGBoost mencapai prestasi yang lebih konsisten dan baik berbanding beberapa model regresi lain dalam analisis pasaran perumahan. Selain itu, integrasi kaedah *Explainable Artificial Intelligence* (XAI) membolehkan faktor utama yang mempengaruhi ramalan harga dikenal pasti dengan lebih telus, sekali gus meningkatkan kebolehfahaman dan kebolehpercayaan sistem (Iban et al., 2022).

Walaupun XGBoost memerlukan pelarasan hiperparameter yang lebih kompleks dan sumber pengiraan yang lebih tinggi, prestasinya dapat dioptimumkan melalui pra-pemprosesan data dan penalaan parameter yang sesuai. Oleh itu, dalam kajian ini, XGBoost digunakan bersama Random Forest Regression untuk tujuan perbandingan prestasi sebelum model terbaik dipilih sebagai model utama dalam sistem Smart Property Valuer.

#### 4.2.2 Model Seni Bina

Rajah 4.3 menunjukkan seni bina model bagi sistem Smart Property Valuer yang direka bentuk untuk menyokong ramalan harga hartanah dan cadangan hartanah berasaskan data. Seni bina ini menerangkan aliran pemprosesan data secara menyeluruh bermula daripada dataset hartanah asal sehingga penghasilan output ramalan harga dan cadangan hartanah kepada pengguna melalui aplikasi web.

Proses ini bermula dengan dataset hartanah asal yang tidak mengandungi maklumat geokodan dan kemudahan sekitar. Dataset ini merangkumi ciri-ciri asas hartanah seperti 'Price', 'Built\_Up\_SF', 'Bathroom', 'Furnishing', 'Bedroom', 'Tenure', 'Car\_Park', 'Agent\_Name', 'Desc', 'Place', 'Area', 'Property\_Type', 'Property\_Address', 'Occupancy', 'Unit\_Type', 'Land\_Size', 'Price\_PSFLand'. Memandangkan data asal ini mengandungi nilai yang tidak seragam dan kekurangan maklumat geospasial, fasa

prapemprosesan data dilaksanakan terlebih dahulu. Fasa ini melibatkan proses pembersihan dan penyeragaman data, pengendalian nilai hilang dan nilai luar (outliers), serta penukaran format data bagi memastikan set data berada dalam keadaan yang sesuai untuk analisis dan pemodelan.

Seterusnya, modul geokodan digunakan untuk menjana koordinat geografi iaitu latitud dan longitud berdasarkan atribut *Place* dan *Area*. Proses ini bertujuan untuk memperkayakan set data dengan maklumat lokasi berasaskan koordinat yang boleh digunakan untuk analisis geospasial. Pada masa yang sama, data berkaitan kemudahan sekitar seperti hospital dan stesen pengangkutan awam (LRT/MRT), yang masing-masing mempunyai koordinat latitud dan longitud, dikumpulkan dan disediakan sebagai input tambahan.

Maklumat koordinat hartanah dan kemudahan sekitar ini kemudiannya digunakan dalam proses pengiraan jarak geospasial. Jarak relatif antara hartanah dan kemudahan terdekat seperti hospital dan stesen LRT/MRT dikira dan dijana sebagai atribut baharu. Atribut jarak ini berfungsi sebagai ciri tambahan yang penting kerana faktor aksesibiliti kepada kemudahan awam mempunyai pengaruh yang signifikan terhadap nilai dan harga hartanah.


Hasil daripada proses geokodan dan pengiraan jarak ini ialah satu dataset lengkap yang mengandungi ciri asal hartanah bersama ciri geospasial baharu seperti latitud, longitud serta jarak ke kemudahan sekitar. Dataset lengkap ini kemudiannya digunakan dalam fasa latihan dan penilaian model. Dalam kajian ini, dua model pembelajaran mesin iaitu Random Forest Regression dan XGBoost Regression dilatih secara berasingan menggunakan dataset yang sama. Prestasi kedua-dua model dinilai berdasarkan metrik penilaian seperti  $R^2$  Score, Mean Absolute Error (MAE) dan Root Mean Squared Error (RMSE) bagi tujuan perbandingan prestasi.

Berdasarkan keputusan penilaian tersebut, satu model ramalan terbaik dipilih dan disimpan untuk digunakan dalam sistem. Proses latihan dan penilaian ini dijalankan secara luar talian (offline) sebelum sistem digunakan oleh pengguna. Semasa fasa penggunaan sistem (runtime), model yang telah disimpan digunakan untuk menjana



ramalan harga hartanah berdasarkan input pengguna tanpa melibatkan sebarang proses latihan atau penilaian lanjut.

Akhir sekali, model ramalan harga yang terpilih diintegrasikan ke dalam aplikasi web berasaskan Flask sebagai antara muka pengguna. Sistem ini memaparkan harga ramalan hartanah dan seterusnya menggunakan kaedah cosine similarity untuk menjana cadangan hartanah yang paling hampir dengan kriteria pengguna berdasarkan harga ramalan dan ciri-ciri lain yang relevan. Melalui seni bina model ini, sistem Smart Property Valuer mampu menyediakan sokongan keputusan yang sistematik, berasaskan data dan berorientasikan pengguna dalam konteks pasaran hartanah Malaysia.



Rajah 4.3 Seni Bina Model Bagi Sistem Smart Property Valuer

### 4.3 STRATEGI EKSPERIMEN

Strategi eksperimen dalam kajian ini dirancang berdasarkan amalan standard dalam kajian ramalan harga hartanah menggunakan model pembelajaran mesin, khususnya Random Forest dan XGBoost seperti yang dibincangkan dalam kajian praktikal yang lalu oleh Schuerch (2021) dan Aditya Gofi (2022). Strategi ini melibatkan pembahagian set data serta penalaan hiperparameter bagi memastikan model yang dibangunkan mempunyai prestasi ramalan yang baik dan keupayaan generalisasi yang tinggi.

#### 4.3.1 Pembahagian Data

Dalam kajian ini, set data lengkap (selepas prapemprosesan, geokodan dan pengiraan jarak) dibahagikan kepada tiga subset utama, iaitu *training*, *validation*, dan *testing* menggunakan nisbah 80:10:10. Pembahagian ini bertujuan memisahkan proses “belajar”, proses “memilih konfigurasi terbaik”, dan proses “menguji prestasi sebenar” supaya penilaian yang dibuat tidak bias.

Set *training* (80%) digunakan untuk melatih model supaya ia mempelajari hubungan antara fitur hartanah dan harga sebenar. Model akan melihat data ini berulang kali semasa proses latihan. Set *validation* (10%) digunakan untuk menilai prestasi model semasa proses penalaan hiperparameter. Dengan kata lain, *validation* membantu menentukan sama ada model menjadi terlalu kompleks atau terlalu ringkas, dan ia digunakan untuk memilih parameter yang memberikan prestasi terbaik tanpa menghafal data latihan. Set *testing* (10%) pula hanya digunakan sekali pada peringkat akhir untuk melaporkan prestasi model selepas semua keputusan pemilihan dibuat. Pendekatan ini selari dengan amalan eksperimen yang biasa digunakan dalam kajian ramalan harga rumah menggunakan Random Forest, di mana pemisahan data membantu menilai kebolehan model meramal data baharu (Schuerch, 2021).

Selain itu, pembahagian data ini juga memastikan eksperimen lebih telus kerana prestasi yang dilaporkan pada test set menggambarkan prestasi model dalam penggunaan sistem sebenar (*runtime*), iaitu apabila pengguna memasukkan input baharu yang tidak pernah dilihat oleh model semasa latihan.

#### 4.3.2 Penalaan Hiperparameter (Hyperparameter Tuning)

Selepas pembahagian data, dua model regresi yang dipilih iaitu Random Forest Regression dan XGBoost Regression dilatih dan ditala (*tuned*) secara berasingan. Penalaan hiperparameter dilakukan kerana prestasi kedua-dua model sangat dipengaruhi oleh parameter seperti bilangan pokok, kedalaman pokok dan kadar pembelajaran. Jika parameter tidak ditala, model mungkin menghasilkan ralat yang tinggi atau mengalami overfitting.

Dalam kajian ini, kaedah GridSearchCV digunakan sebagai pendekatan penalaan hiperparameter. GridSearchCV akan menguji beberapa kombinasi hiperparameter yang telah ditetapkan dan memilih kombinasi yang menghasilkan prestasi terbaik berdasarkan metrik ralat (contohnya  $R^2$ , MAE atau RMSE). Proses ini sistematik kerana setiap kombinasi dinilai secara konsisten, dan ia sesuai untuk kajian yang memerlukan ketelusan dalam pemilihan model.

Bagi Random Forest Regression, hiperparameter utama yang ditala lazimnya termasuk bilangan pokok keputusan ( $n\_estimators$ ), kedalaman maksimum pokok ( $max\_depth$ ), serta parameter yang mengawal minimum sampel untuk pemecahan nod ( $min\_samples\_split$  dan  $min\_samples\_leaf$ ). Secara konseptual, bilangan pokok yang lebih banyak boleh meningkatkan kestabilan ramalan, manakala kedalaman pokok yang terlalu besar boleh menyebabkan model menghafal data latihan. Oleh itu, penalaan hiperparameter membantu mencari keseimbangan antara ketepatan dan kebolehan generalisasi, seperti yang dibincangkan dalam panduan langkah demi langkah Random Forest untuk ramalan harga rumah (Schuerch, 2021).

Bagi XGBoost Regression, hiperparameter yang kritikal termasuk bilangan pokok ( $n\_estimators$ ), kadar pembelajaran ( $learning\_rate$ ), kedalaman maksimum ( $max\_depth$ ), serta kadar subsampling dan  $colsample\_bytree$  yang mengawal jumlah data dan ciri yang digunakan bagi setiap pokok. Parameter seperti  $learning\_rate$  mengawal sejauh mana setiap pokok baharu membetulkan kesilapan ramalan terdahulu; nilai yang terlalu besar boleh menyebabkan model tidak stabil, manakala nilai yang terlalu kecil boleh memerlukan lebih banyak pokok dan meningkatkan masa latihan. Penalaan hiperparameter ini sejajar dengan pendekatan yang dihuraikan dalam kajian

ramalan harga rumah menggunakan XGBoost, yang menekankan kepentingan pelarasan parameter untuk meningkatkan prestasi ramalan (Aditya Gofi, 2022).

Dalam pelaksanaan eksperimen, setiap kombinasi hiperparameter bagi kedua-dua model dinilai menggunakan set validation (atau melalui *cross-validation* dalam GridSearchCV) dengan metrik utama  $R^2$ , MAE dan RMSE. Kombinasi yang memberikan ralat terendah dipilih sebagai model teroptimum. Selepas itu, model teroptimum akan diuji menggunakan set testing untuk mendapatkan prestasi akhir yang dilaporkan dalam kajian. Model terbaik antara Random Forest dan XGBoost kemudian dipilih dan disimpan untuk digunakan dalam sistem Smart Property Valuer semasa fasa runtime.

#### 4.4 REKA BENTUK PENILAIAN

Keberkesanan model yang dibangunkan diuji dan dibandingkan dengan parameter prestasi (*Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)* dan *Coefficient of Determination ( $R^2$ )*. Metrik-metrik ini digunakan secara meluas dalam kajian ramalan harga rumah kerana keupayaannya menilai ketepatan ramalan model bagi nilai berterusan.

##### 4.4.1 Metrik Prestasi

###### a) Mean Absolute Error (MAE)

Mean Absolute Error (MAE) mengukur purata perbezaan mutlak antara nilai harga sebenar dan nilai harga yang diramalkan oleh model. Metrik ini memberikan gambaran purata kesilapan ramalan dalam unit yang sama dengan harga hartanah, menjadikannya mudah untuk ditafsir. Nilai MAE yang lebih rendah menunjukkan prestasi model yang lebih baik kerana kesilapan ramalan secara purata adalah kecil.

Secara matematik, MAE ditakrifkan seperti berikut:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

di mana  $y_i$  mewakili nilai harga sebenar,  $\hat{y}_i$  mewakili nilai harga ramalan oleh model, dan  $n$  ialah bilangan sampel data.

**b) Root Mean Squared Error (RMSE)**

Root Mean Squared Error (RMSE) mengukur punca kuasa dua kepada purata kuasa dua perbezaan antara nilai sebenar dan nilai ramalan. Berbanding MAE, RMSE memberikan penalti yang lebih besar kepada kesilapan ramalan yang tinggi kerana ralat dikuasakan dua sebelum dipuratakan. Oleh itu, RMSE sesuai digunakan untuk menilai kesan ralat besar yang mungkin berlaku dalam ramalan harga hartanah bernilai tinggi.

Formula bagi RMSE adalah seperti berikut:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Nilai RMSE yang lebih rendah menunjukkan bahawa model menghasilkan ramalan yang lebih hampir kepada nilai sebenar.

**c) Coefficient of Determination ( $R^2$ )**

*Coefficient of Determination* atau  $R^2$  mengukur sejauh mana variasi dalam nilai harga hartanah sebenar dapat diterangkan oleh model ramalan. Nilai  $R^2$  berada antara 0 hingga 1, di mana nilai yang lebih hampir kepada 1 menunjukkan keupayaan model yang lebih baik dalam menerangkan variasi harga, manakala nilai yang rendah menunjukkan hubungan yang lemah antara ciri input dan harga hartanah.

Secara matematik,  $R^2$  ditakrifkan sebagai:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

di mana ialah purata nilai harga sebenar. Dalam konteks kajian ini,  $R^2$  digunakan sebagai metrik sokongan bagi menilai keupayaan model dalam menerangkan variasi

harga hartanah, manakala MAE dan RMSE digunakan sebagai metrik utama untuk mengukur kesilapan ramalan.

#### 4.5 SPESIFIKASI KEPERLUAN SISTEM

Bahagian ini menerangkan keperluan fungsian serta spesifikasi perkakasan dan perisian bagi sistem Smart Property Valuer. Keperluan fungsian mentakrifkan fungsi utama yang perlu disediakan oleh sistem kepada pengguna, manakala spesifikasi perkakasan dan perisian pula menerangkan keperluan minimum bagi pembangunan, latihan model dan penggunaan sistem.


##### 4.5.1 Keperluan Fungsian

###### A) Senarai Fungsi

Jadual 4.1 Keperluan fungsian sistem

| Bil | Keperluan Fungsian Sistem                                                                                                                                                                                                   |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1   | Sistem hendaklah membenarkan pengguna memasukkan maklumat hartanah seperti jenis hartanah, anggaran keluasan, bilangan bilik tidur, bilangan bilik air, bilangan tempat letak kereta serta maklumat lokasi ( <i>Area</i> ). |
| 2   | Sistem hendaklah mengesahkan input pengguna bagi memastikan nilai yang dimasukkan adalah sah dan munasabah sebelum proses ramalan harga dijalankan.                                                                         |
| 3   | Sistem hendaklah menjana harga hartanah ramalan berdasarkan maklumat input pengguna menggunakan model pembelajaran mesin yang telah dilatih dan dipilih.                                                                    |
| 4   | Sistem hendaklah memaparkan harga hartanah ramalan kepada pengguna berdasarkan input yang dipilih oleh pengguna                                                                                                             |
| 5   | Sistem hendaklah menjana senarai cadangan hartanah yang paling serupa dengan keperluan pengguna dan harga ramalan menggunakan kaedah <i>cosine similarity</i> .                                                             |
| 6   | Sistem hendaklah memaparkan senarai hartanah yang dicadangkan berserta maklumat ringkas seperti anggaran harga, jenis hartanah dan lokasi.                                                                                  |
| 7   | Sistem hendaklah membenarkan pengguna memilih salah satu hartanah yang dicadangkan untuk melihat maklumat yang lebih terperinci.                                                                                            |
| 8   | Sistem hendaklah menyediakan fungsi carian dan penapisan hartanah berdasarkan kriteria seperti julat harga, lokasi, jenis hartanah dan bilangan bilik.                                                                      |

## B) Rajah Kes Guna (Use Case Diagram)



Rajah 4.4 Kes Guna Sistem Smart Property Valuer

Rajah 4.4 Kes Guna ini menunjukkan interaksi antara pengguna dan sistem Smart Property Valuer. Pengguna boleh memasukkan maklumat hartanah untuk tujuan ramalan harga atau melakukan carian dan tapisan hartanah. Proses ramalan harga hartanah memerlukan maklumat hartanah sebagai input, manakala hasil ramalan akan digunakan untuk memaparkan cadangan senarai hartanah yang bersesuaian. Pengguna juga boleh melihat maklumat terperinci bagi setiap hartanah yang dipaparkan.



#### 4.5.2 Spesifikasi Perkakasan Dan Perisian

##### A) Keperluan Perisian (Software)

Jadual di bawah menjelaskan keperluan persisian bagi pembangunan sistem ini serta keperluan perisian yang diperlukan oleh pengguna.

##### Pembangunan:

Jadual 4.2 Keperluan Perisian Pembangunan (SOFTWARE)

| Aspek                        | Perisian             | Penerangan                                                                                                                                  |
|------------------------------|----------------------|---------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Bahasa Pengaturcaraan</b> | Python               | Digunakan sebagai bahasa utama untuk membangunkan sistem, termasuk pemprosesan data, latihan model pembelajaran mesin dan integrasi sistem. |
| <b>Libraries</b>             | Pandas, Numpy,       | Digunakan untuk pemprosesan, pembersihan dan analisis data hartanah.                                                                        |
|                              | Scikit-learn         | Digunakan untuk pembinaan model Random Forest Regression, metrik penilaian (MAE, RMSE, R <sup>2</sup> ) dan kaedah cosine similarity.       |
|                              | XGBoost              | Digunakan untuk melatih model XGBoost Regression bagi tujuan perbandingan prestasi ramalan harga hartanah.                                  |
|                              | GeoPy / API Geokodan | Digunakan untuk menjana koordinat latitud dan longitud berdasarkan lokasi hartanah serta menyokong pengiraan jarak ke kemudahan sekitar.    |
| <b>Framework</b>             | Flask                | Digunakan untuk membangunkan aplikasi web dan mengintegrasikan model ramalan harga serta modul cadangan hartanah.                           |
| <b>IDE</b>                   | GoogleColab          | Digunakan untuk menjalankan analisis data, latihan model dan eksperimen pembelajaran mesin.                                                 |
| <b>Pangkalan Data</b>        | MYSQL                | Digunakan untuk menyimpan data hartanah, data geospatial dan menyokong fungsi carian serta penapisan dalam sistem.                          |

**Pengguna:**

Jadual 4.3 Keperluan Perisian Pengguna (SOFTWARE)

| Aspek       | Perisian             | Penerangan                                   |
|-------------|----------------------|----------------------------------------------|
| Pelayar Web | Chrome,Firefox, Edge | Untuk mengakses sistem Smart Property Valuer |

**B) Keperluan Perkakasan (Hardware)**

Jadual di bawah menjelaskan spesifikasi minimum bagi keperluan perkakasan bagi pembangunan sistem ini serta keperluan perkakasan yang diperlukan oleh pengguna.


Jadual 4.4 Keperluan Perkakasan Pembangunan dan Pengguna (HARDWARE)

| Perkakasan                    | Keperluan Pembangunan    | Keperluan Pengguna           |
|-------------------------------|--------------------------|------------------------------|
| Pemproses (CPU)               | Intel Core i5 dan setara | Intel Core i3/i5 dan setara  |
| Memori (RAM)                  | 8GB                      | 4-8GB                        |
| Storan                        | 10 GB                    | Tidak memerlukan storan khas |
| OS                            | Windows 10/11            | Windows/Android/Ios          |
| Unit Pemprosesan Grafik (GPU) | Tidak diwajibkan         | Tidak diwajibkan             |
| Peranti                       | Komputer riba/PC         | Telefon/Tablet/komputer riba |
| Sambungan Internet            | Diperlukan               | Diperlukan                   |

## 4.6 REKA BENTUK SISTEM DAN ANTARA MUKA

### 4.6.1 Sistem Seni Bina


#### Lapisan Antara Muka Pengguna (Aplikasi Web)



Rajah 4.5

Seni Bina Sistem Smart PropertyValuer


#### 4.6.2 Proses Carta Alir




Rajah 4.6

Carta Alir Sistem Smart PropertyValuer


### 4.6.3 Reka Bentuk Antara Muka Pengguna



Rajah 4.7 Reka Bentuk Antara Muka Halaman Utama Smart Property Valuer



Rajah 4.8 Reka Bentuk Antara Muka Halaman Ramalan Smart Property Valuer



Rajah 4.9 Reka Bentuk Antara Muka Halaman Ramalan Harga Smart Property Valuer

Rajah 4.10 Reka Bentuk Antara Muka Halaman Carian Tapisan Hartanah Smart Property Valuer

| HARTANAH                  | BILIK | TANDAS | SAIZ       | HARGA      | TINDAKAN |
|---------------------------|-------|--------|------------|------------|----------|
| Residensi Aurora<br>Bangi | 3     | 2      | 1,050 sqft | RM 520,000 | Lihat    |
| Vista Harmoni<br>Bangi    | 4     | 3      | 1,320 sqft | RM 610,000 | Lihat    |
| Taman Seri Murni<br>Bangi | 2     | 2      | 900 sqft   | RM 470,000 | Lihat    |

Rajah 4.11 Reka Bentuk Antara Muka Halaman Paparan Carian Hartanah Smart Property Valuer

Rajah 4.12 Reka Bentuk Antara Muka Halaman Butiran Hartanah Smart Property Valuer

#### 4.7 RUMUSAN

Bab ini membicarakan reka bentuk sistem, pemilihan algoritma pembelajaran mesin serta strategi penilaian yang digunakan dalam pembangunan sistem Smart Property Valuer. Pemilihan Random Forest Regression dan XGBoost Regression adalah berdasarkan keupayaannya mengendalikan data tabular dan hubungan tidak linear antara ciri hartanah dan harga pasaran.

Selain itu, Bab ini turut menghuraikan seni bina sistem dan aliran pemprosesan data, bermula daripada pra-pemprosesan dan geokodan sehingga integrasi model ramalan ke dalam aplikasi web berasaskan Flask. Strategi eksperimen, termasuk pembahagian data, penalaan hiperparameter dan penilaian prestasi menggunakan metrik MAE, RMSE dan  $R^2$ , turut dibincangkan bagi memastikan ketepatan dan kestabilan ramalan.

Selain aspek teknikal, reka bentuk antara muka pengguna dan integrasi modul ramalan serta cadangan hartanah turut diberi perhatian bagi memastikan sistem mesra pengguna dan praktikal. Secara keseluruhan, Bab IV menyediakan asas teknikal dan metodologi yang kukuh untuk analisis hasil kajian yang dibentangkan dalam bab seterusnya.

## RUJUKAN

- Ho, W.K.O., Tang, B.S. & Wong, S.W. 2021. Predicting property prices with machine learning algorithms. *Journal of Property Research* 38(1): 48–70.
- Mathotaarachchi, K.V., Hasan, R. & Mahmood, S. 2024. Advanced Machine Learning Techniques for Predictive Modeling of Property Prices. *Information (Switzerland)* 15(6)
- Pastukh, O. & Khomyshyn, V. 2023. Using ensemble methods of machine learning to predict real estate prices.
- Aditya Gofi. 2022. Predicting house prices with XGBoost: A machine learning journey. <https://medium.com/@adityagofi/predicting-house-prices-with-xgboost-a-machine-learning-journey-b8ed827cd05f>
- Bank Negara Malaysia. (2020). *Laporan Kestabilan Kewangan 2020*. Kuala Lumpur: Bank Negara Malaysia.
- Hajjiyanni, N. & Stylianou, V. 2025. Machine learning for real estate price prediction. *International Student Research Journal*. <https://www.issrj.org/wp-content/uploads/2025/04/Machine-Learning-for-Real-Estate-Price-Prediction.pdf>
- Hastie, T., Tibshirani, R. & Friedman, J. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. New York: Springer.
- Haw, S.-C. & Muthu, K. S. 2022. *A case study using machine learning techniques for prediction of house prices in WP Malaysia*. Atlantis Press.
- Truong, Q., Nguyen, M., Dang, H. & Mei, B. 2020. Housing price prediction via improved machine learning techniques. *Procedia Computer Science*.
- Tekouabou, Ş. C. G., Kameni, E. D., Filali, Y. & Idrissi Gartoumi, K. 2024. AI-based machine learning techniques for urban real estate prediction. *International Journal of Intelligent Systems and Applications*.
- Willmott, C. J. & Matsuura, K. 2005. Advantages of the mean absolute error over the root mean square error. *Climate Research* 30(1): 79–82.
- Schuerch, S. 2021. Beginner's guide to predicting house prices with random forest: Step-by-step introduction. [https://medium.com/@schuerch\\_sarah/beginners-guide-to-predicting-house-prices-with-random-forest-step-by-step-introduction-with-a-aee81daae3ee](https://medium.com/@schuerch_sarah/beginners-guide-to-predicting-house-prices-with-random-forest-step-by-step-introduction-with-a-aee81daae3ee)
- Scikit-learn. 2023. Regression metrics. [https://scikit-learn.org/stable/modules/model\\_evaluation.html](https://scikit-learn.org/stable/modules/model_evaluation.html)



